Modelos Lineares e Grafos

'Tudo é correlacionado. Mas certas coisas são mais correlacionadas que outras'

Enzo e Vítor

USP - ICMC

1 Introdução

2 Espacialidade

3 Resultados

Aluguel em São Paulo



Aluguel em São Paulo

Para entender o preço do aluguel em São Paulo, temos um dataset com características de apartamentos e o preço do aluguel de cada um.

preço $\sim$ area + quartos + garagem ...

Aluguel em São Paulo

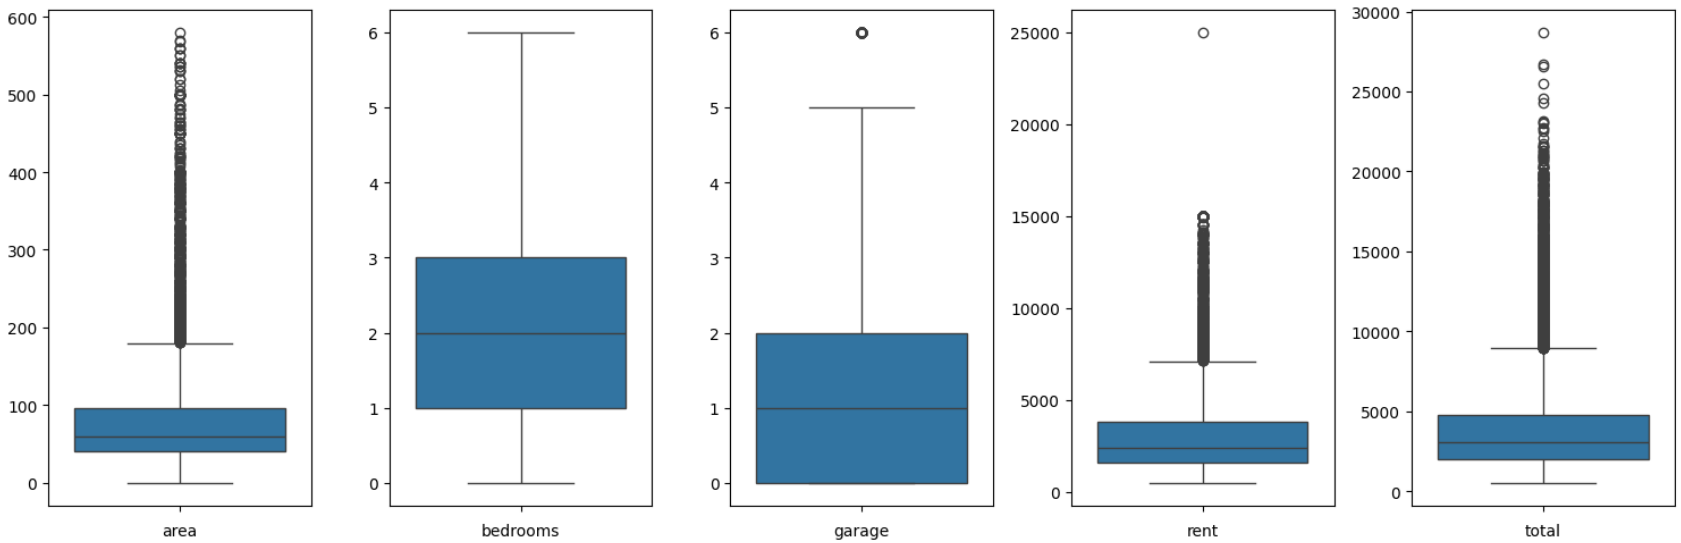


Figure 1: Box plot das variáveis

Aluguel em São Paulo

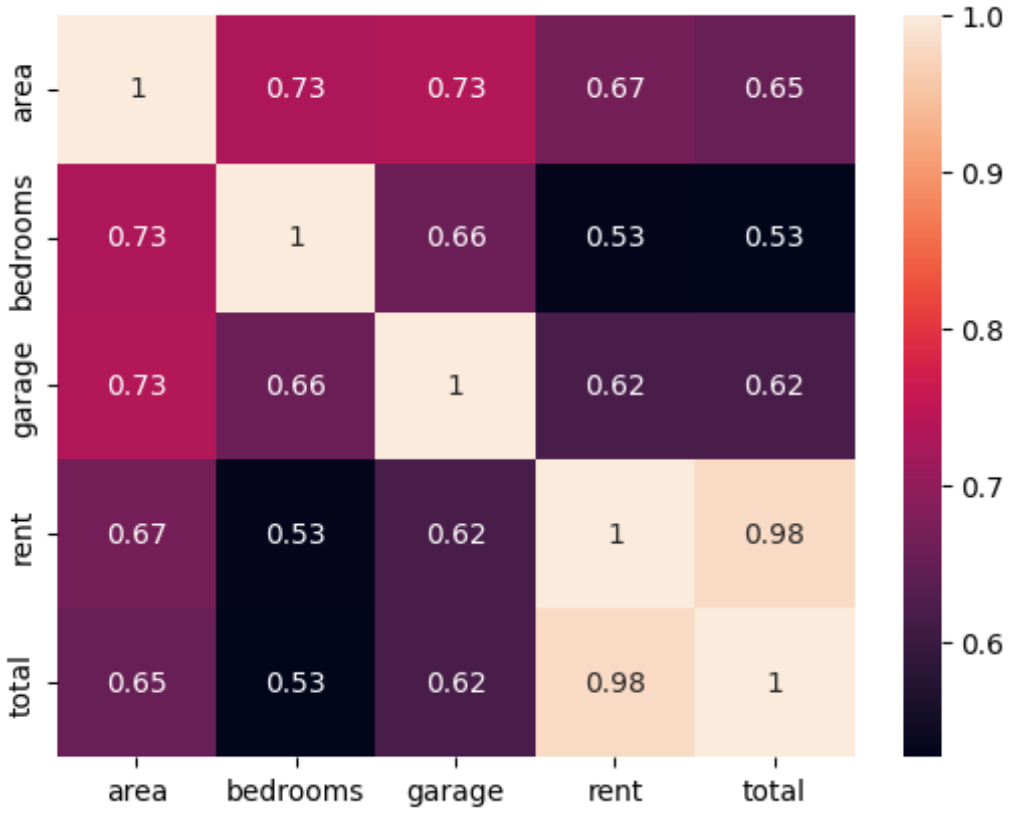


Figure 2: Correlação entre as variáveis

Aluguel em São Paulo

Ajustamos um modelo linear $y_i = X_i\beta + \epsilon_i, \forall i$ e encontramos coeficientes β que indicam como cada covariável influencia no preço final.

Statistic	Value
Dep. Variable	log rent
Model	OLS
No. Observations	11657
R-squared	0.563
Prob (F-statistic)	0.00

Term	coef	std err	t	$P > \|t\|$
const	7.2700	0.006	1124.248	0.000
area	0.0057	0.000	54.590	0.000
...	...	...	...	...

Aluguel em São Paulo

Para checar a eficiência do modelo, vamos fazer um teste: prever o preço de um Loft em Pinheiros. O imóvel possui 1 quarto, 0 garagens, $20m^2$ de área, etc.

Identificamos imediatamente que o aluguel é caro. Mas ao contar apenas as características do imóvel, o modelo não consegue quantificar o preço do aluguel corretamente.

Aluguel em São Paulo

Devemos considerar a espacialidade no modelo!

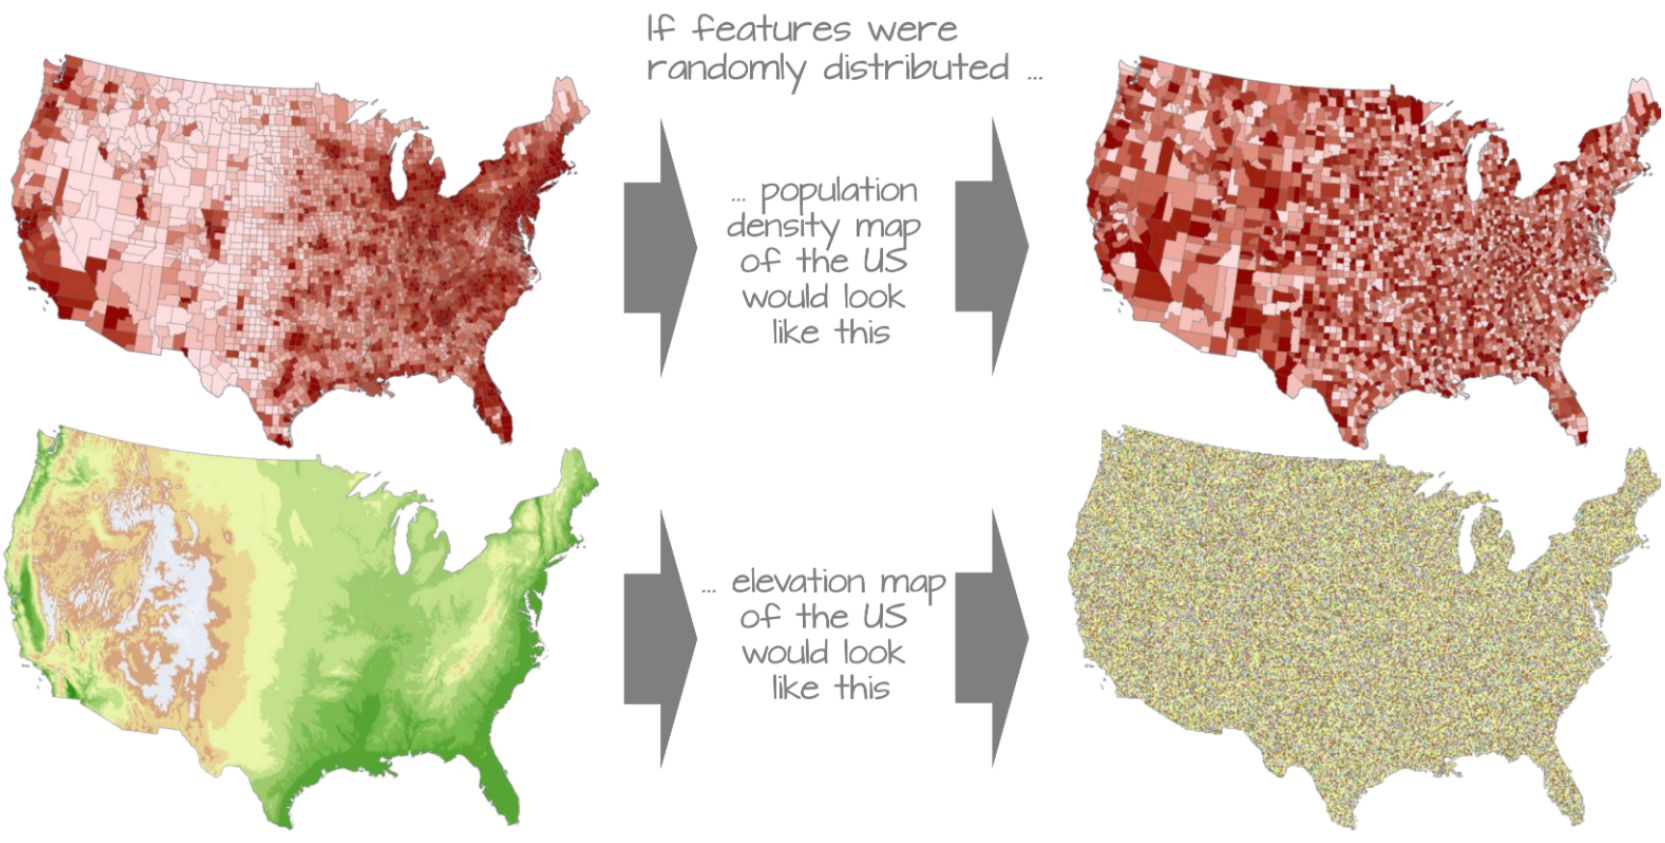


Primeira Lei da Geografia

> *"Tudo é correlacionado. Mas certas coisas são mais correlacionadas que outras"*

Waldo Tobler

Primeira Lei da Geografia



Credit: Manuel Gimond

Spatial Autoregressive Model

O valor do aluguel de uma apartamento em São Paulo depende das covariáveis e também do preço dos apartamentos vizinhos.

$y_i = \sum_{j \in \text{vizinhos}} y_j w_{ij} + X_i \beta + \epsilon_i$

Nesse modelos, os termos w_{ij} representam a relação entre as amostras i e j.

Spatial Autoregressive Model

Teste I de Moran

Como saber se meus dados são espacialmente correlacionados?

$$I = \frac{N}{\sum_{i,j} W_{ij}} \frac{y^T W y}{y^T y}$$

Sob a hipótese nula de **não correlação espacial**, o valor esperado de I é

$$E(I) = \frac{-1}{N-1}$$

Isso significa que para muitas amostras, o valor esperado tende a 0.

Spatial Autoregressive Model

Para encontrar os termos w_{ij} podemos utilizar a matriz de adjacências de um grafo. Para o caso do aluguel em São Paulo, podemos considerar a distância entre as casas para montar a Matriz de Adjacências.

$$w_{ij} = \begin{cases} 1, d(i,j) < c \\ 0, c.c. \end{cases}$$

Spatial Autoregressive Model

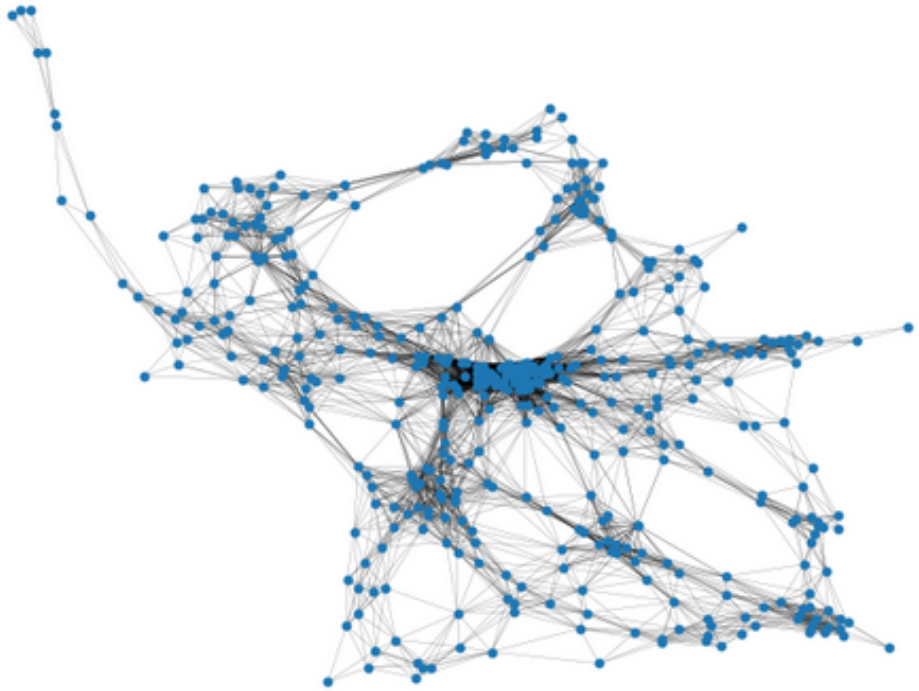


Figure 3: Grafo construído a partir do Dataset. Cada apartamento é um vértice e estão conectados se distância < 3000m

Spatial Autoregressive

Mais especificamente, os modelos costumam utilizar uma versão normalizada da matriz de adjacências. Nela, o valor de cada arestas é normalizado de acordo com o número de conexões dos nós. Essa matriz tem propriedades interessantes que vamos considerar.

$$W_{\text{norm}} = D^{-1/2} W D^{-1/2}$$

Spatial Autoregressive Model

O termo y aparece em ambos lados da equação (por isso é Autoregressivo, afinal). Como encontrar estimar β?

Primeiro escrevemos na forma matricial.

$$Y = WY + X\beta + \epsilon$$

Então, uma simples manipulação permite resolver.

$$Y - WY = X\beta + \epsilon$$

$$Y(I - W) = X\beta + \epsilon$$

$$Y = (I - W)^{-1}(X\beta + \epsilon)$$

Portanto, basta multiplicar X pelo termo $(I - W)^{-1}$ e resolver o sistema linear resultante.

Efeito do operador $(I - \rho W)^{-1}$

Para visualizar o efeito, vamos considerar a aplicação do operador sobre um vetor $X = [1, 0, 0, ..., 0, 0, -1]$ que possui matriz de adjacência normalizada W.

Consideramos um termo ρ que permite regularizar a relação.

Efeito do operador $(I - \rho W)^{-1}$

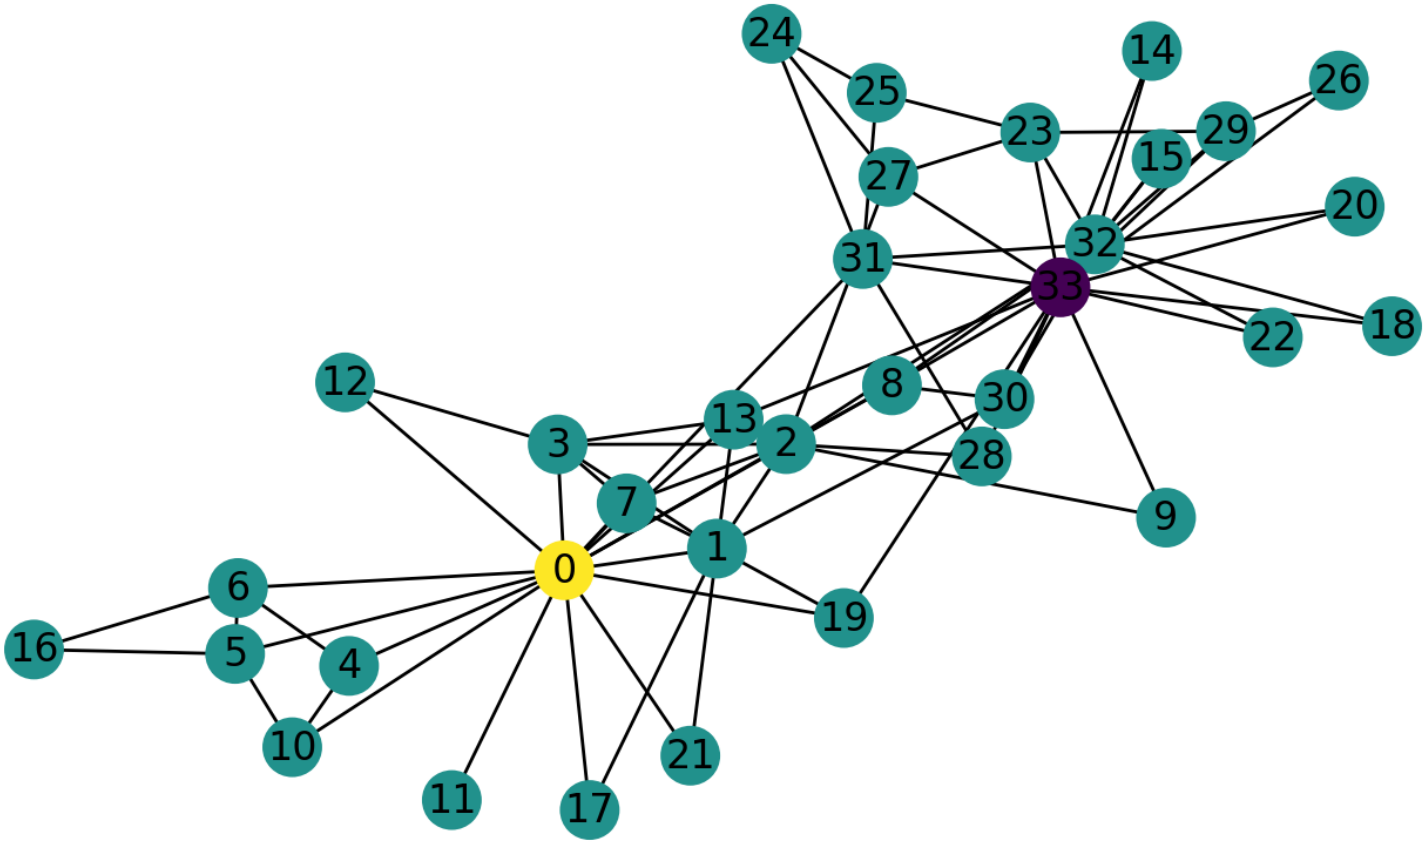


Figure 4: Aplicação do operador com $\rho = 0$ (não há relação espacial)

Efeito do operador $(I - \rho W)^{-1}$

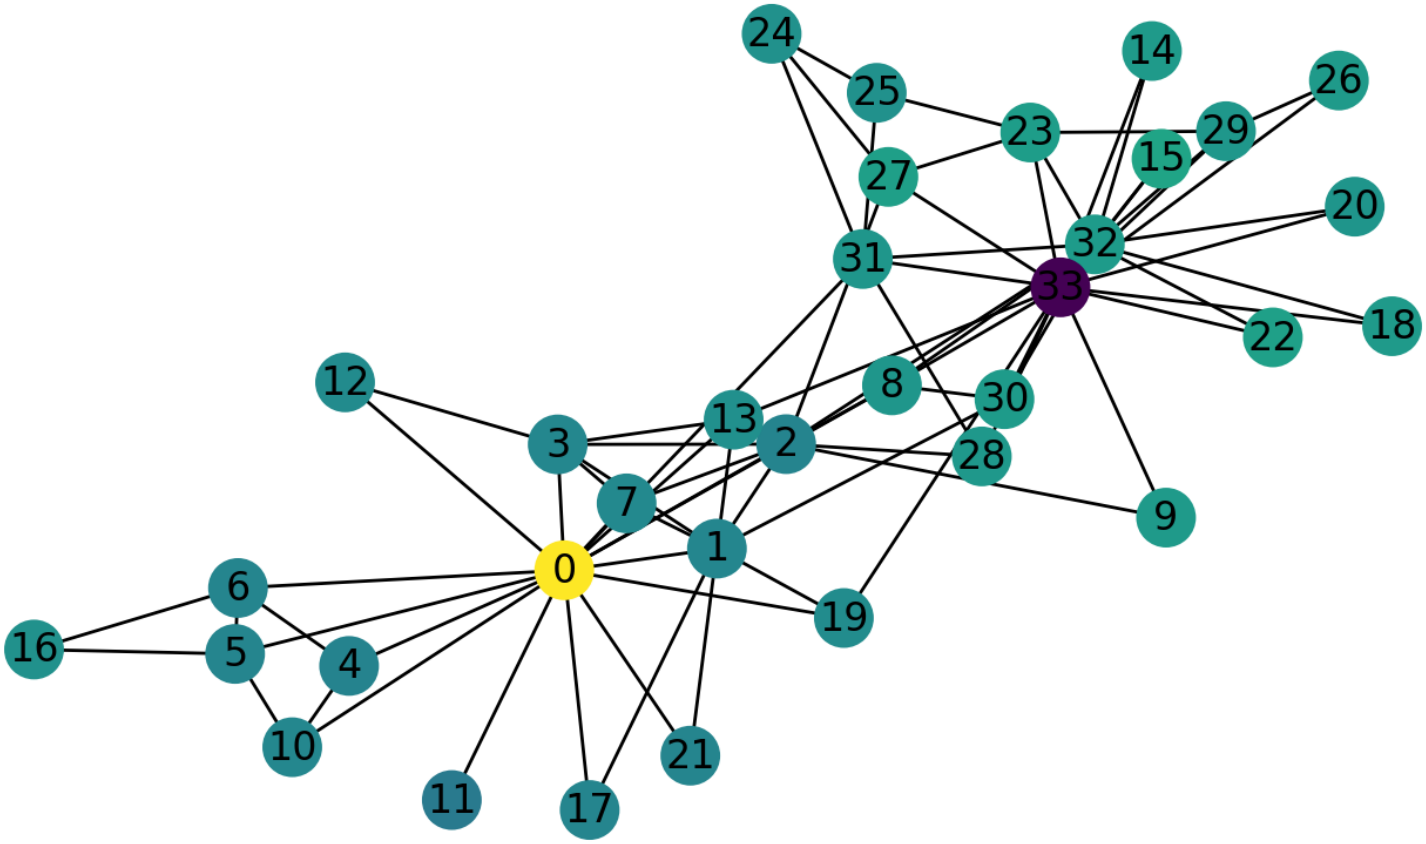


Figure 5: Aplicação do operador com $\rho = 0.25$

Efeito do operador $(I - \rho W)^{-1}$

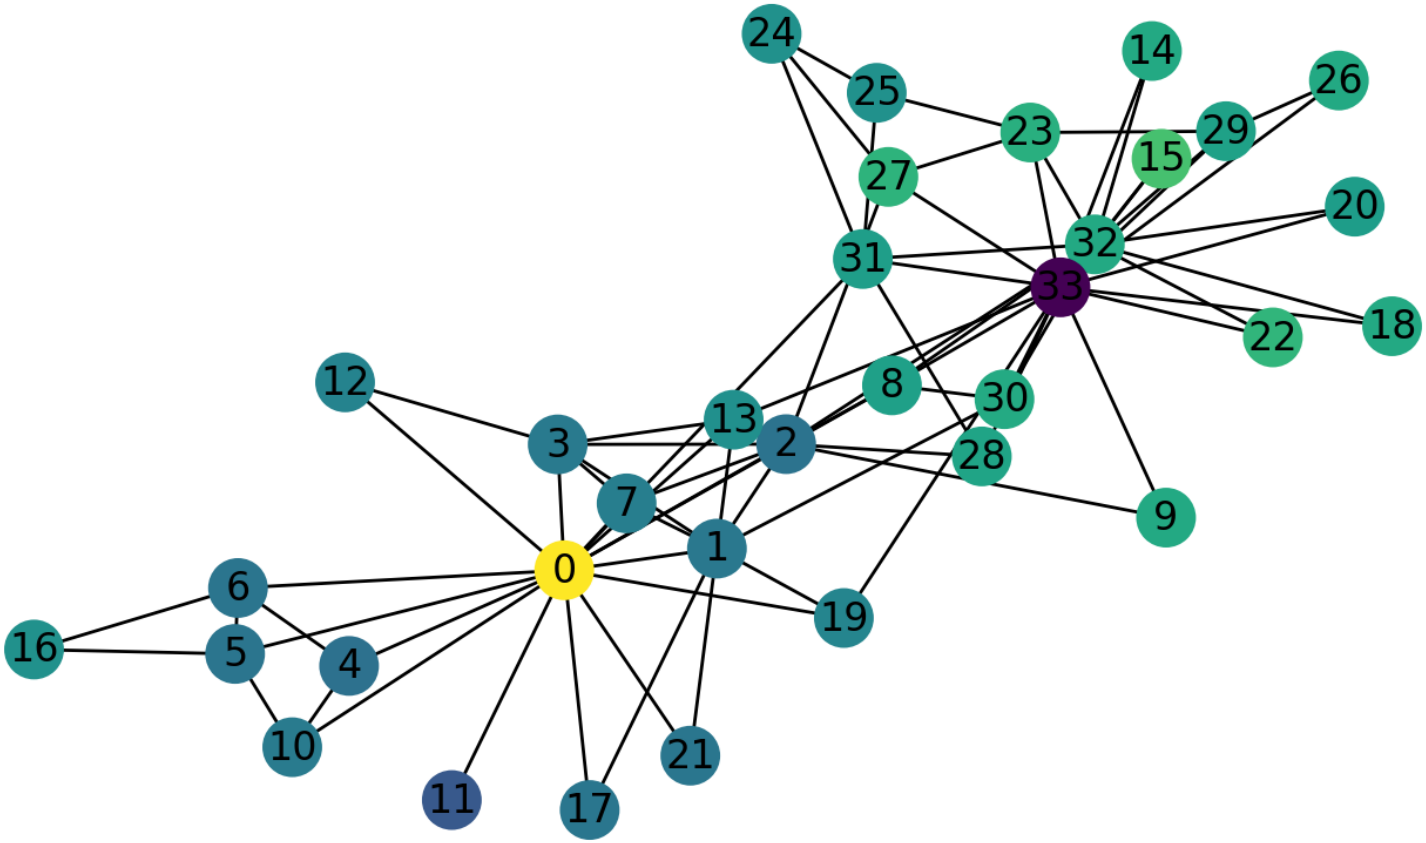


Figure 6: Aplicação do operador com $\rho = 0.6$

Efeito do operador $(I - \rho W)^{-1}$

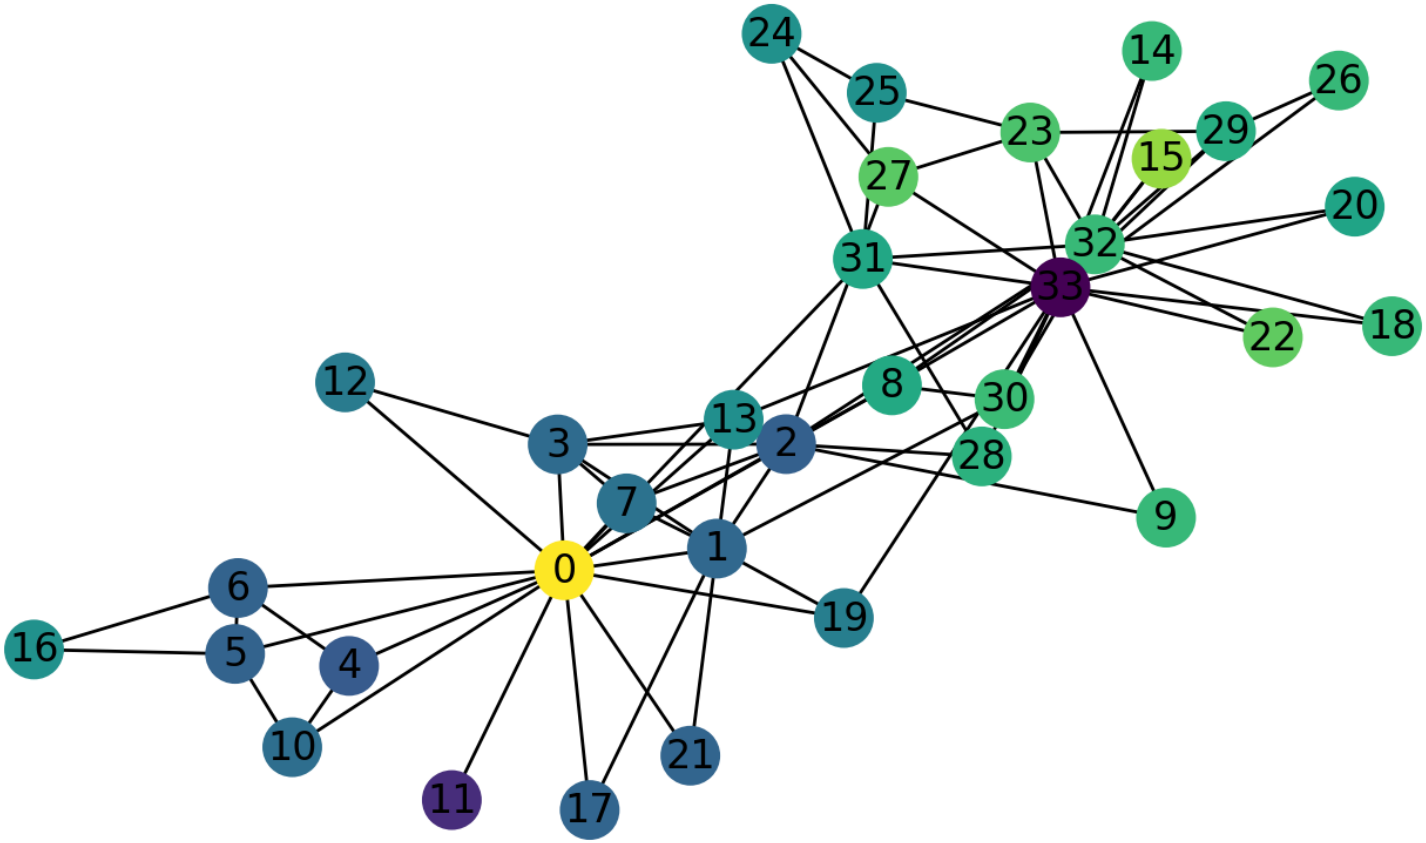


Figure 7: Aplicação do operador com $\rho = 1$

Efeito do operador $(I - \rho W)^{-1}$

Esperávamos que os vizinhos dos nós 0 e 33 recebessem valor similar, porém isso não aconteceu!

Uma outra visão sobre Modelos Espaciais

- Enquanto os Modelos Lineares foram desenvolvidos, a área de Deep Learning também se desenvolveu.
- CNNs são ferramentas poderosíssimas para lidar com imagens. O princípio de funcionamento de uma CNN é aplicar convoluções sobre a imagem e entender o resultado final.
- A Convolução é uma operação que faz a média dos pixels em uma área, gerando um efeito de *blur*.

Uma outra visão sobre Modelos Espaciais

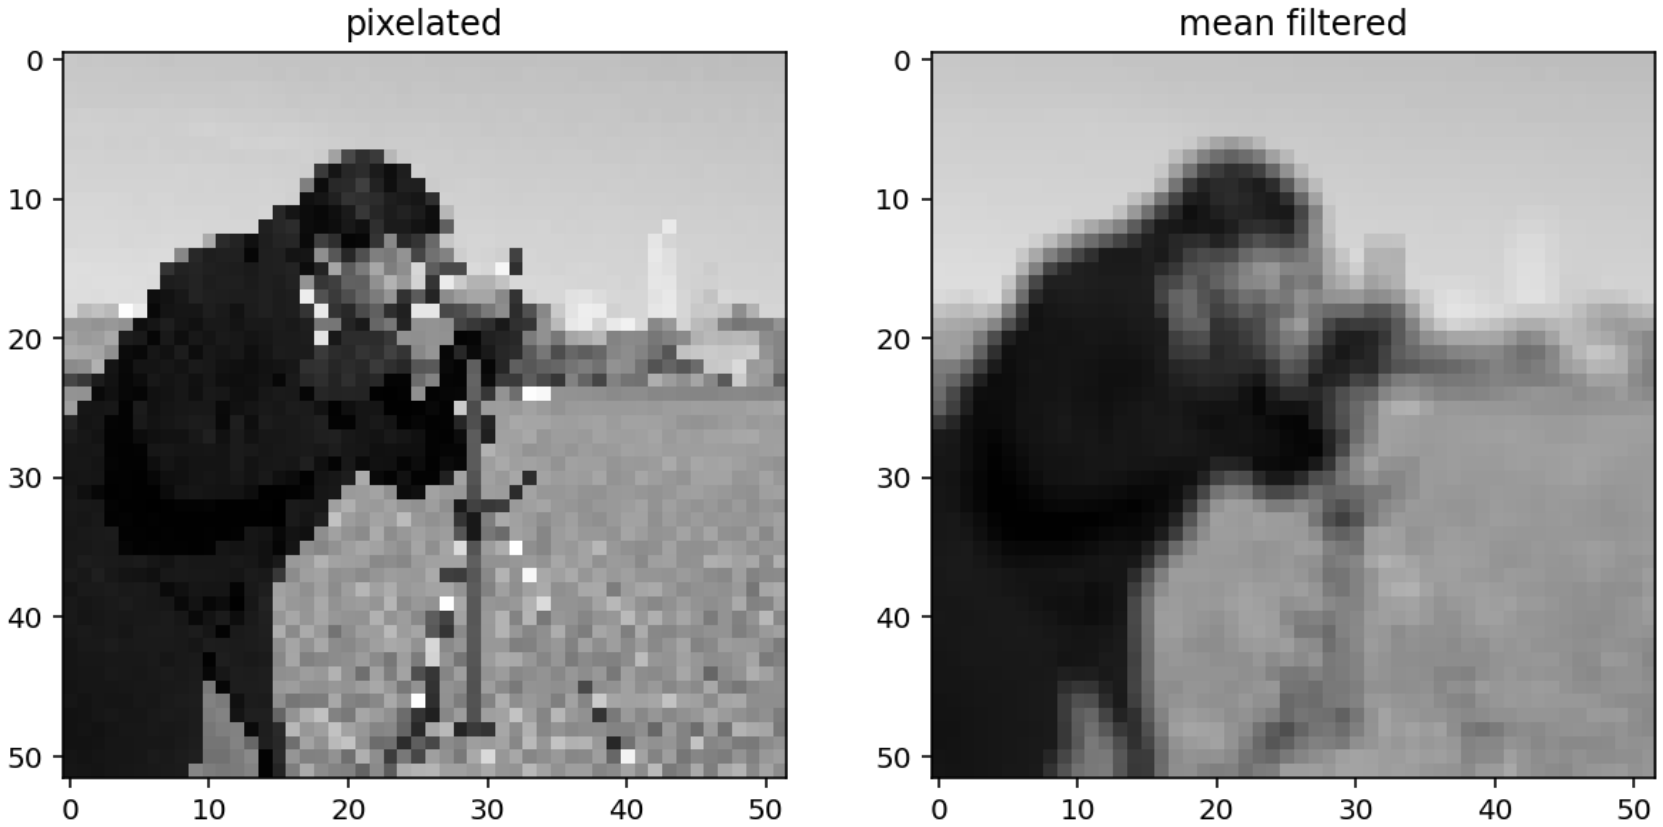


Figure 8: Convolução sobre uma imagem pixelada

Uma outra visão sobre Modelos Espaciais

- Baseado em CNNs, os cientistas desenvolveram GCNs, que seguem o mesmo princípio de convolução, porém para dados estruturados por grafos.

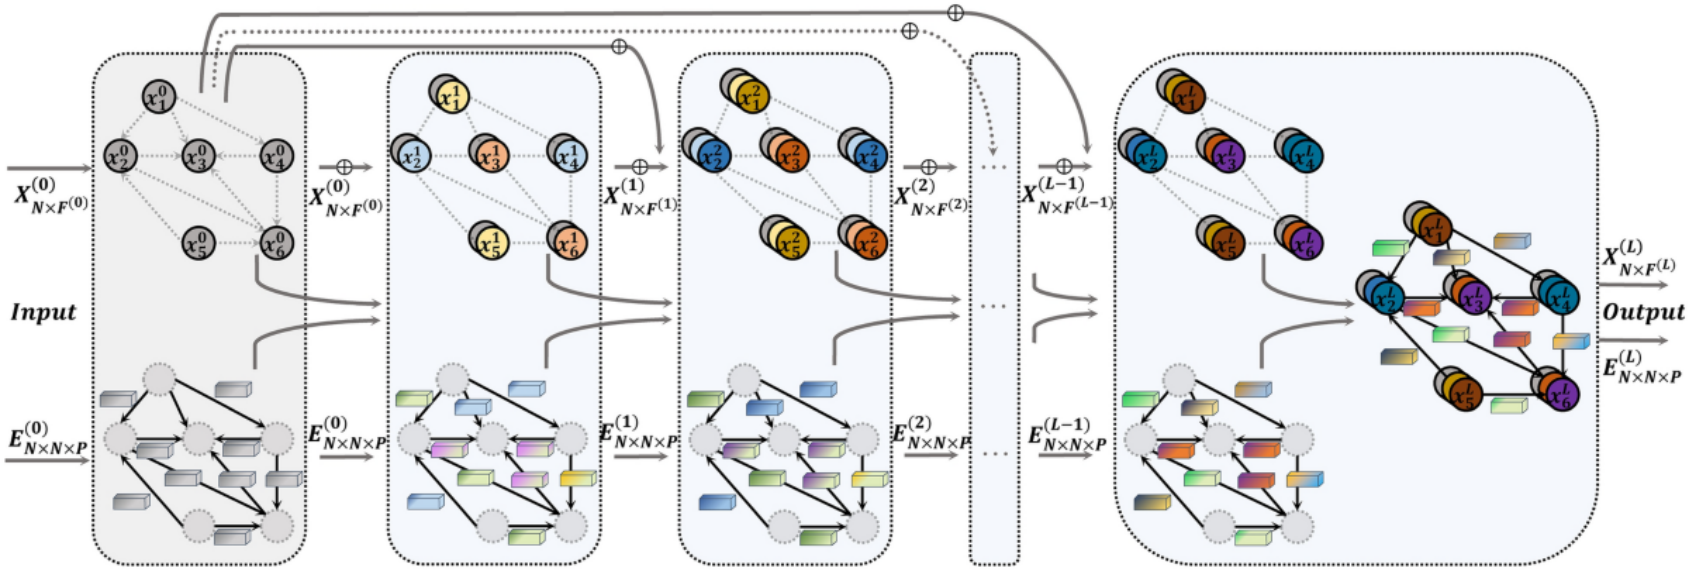


Figure 9: Graph Convolutional Network para Classificação de Nós

Uma outra visão sobre Modelos Espaciais

- Podemos aplicar uma GCN para estimar o preço do aluguel em SP?
- Certamente, porém vamos perder explicabilidade sobre as covariáveis devido ao número de camadas não lineares. O que fazer?

Uma outra visão sobre Modelos Espaciais

Retiramos as não linearidades! Assim, obtemos um Modelo Linear que faz a convolução das covariáveis.

$Y = \exp(-tL)X\beta$

Onde L é a matriz Laplaciana e $\exp(-tL)$ representa a difusão ao longo do tempo t.

Para fins numéricos, a **matriz Laplaciana normalizada** é tradicionalmente utilizada: $L = I - W$, onde W é a matriz de adjacências normalizada.

Efeito do operador de difusão

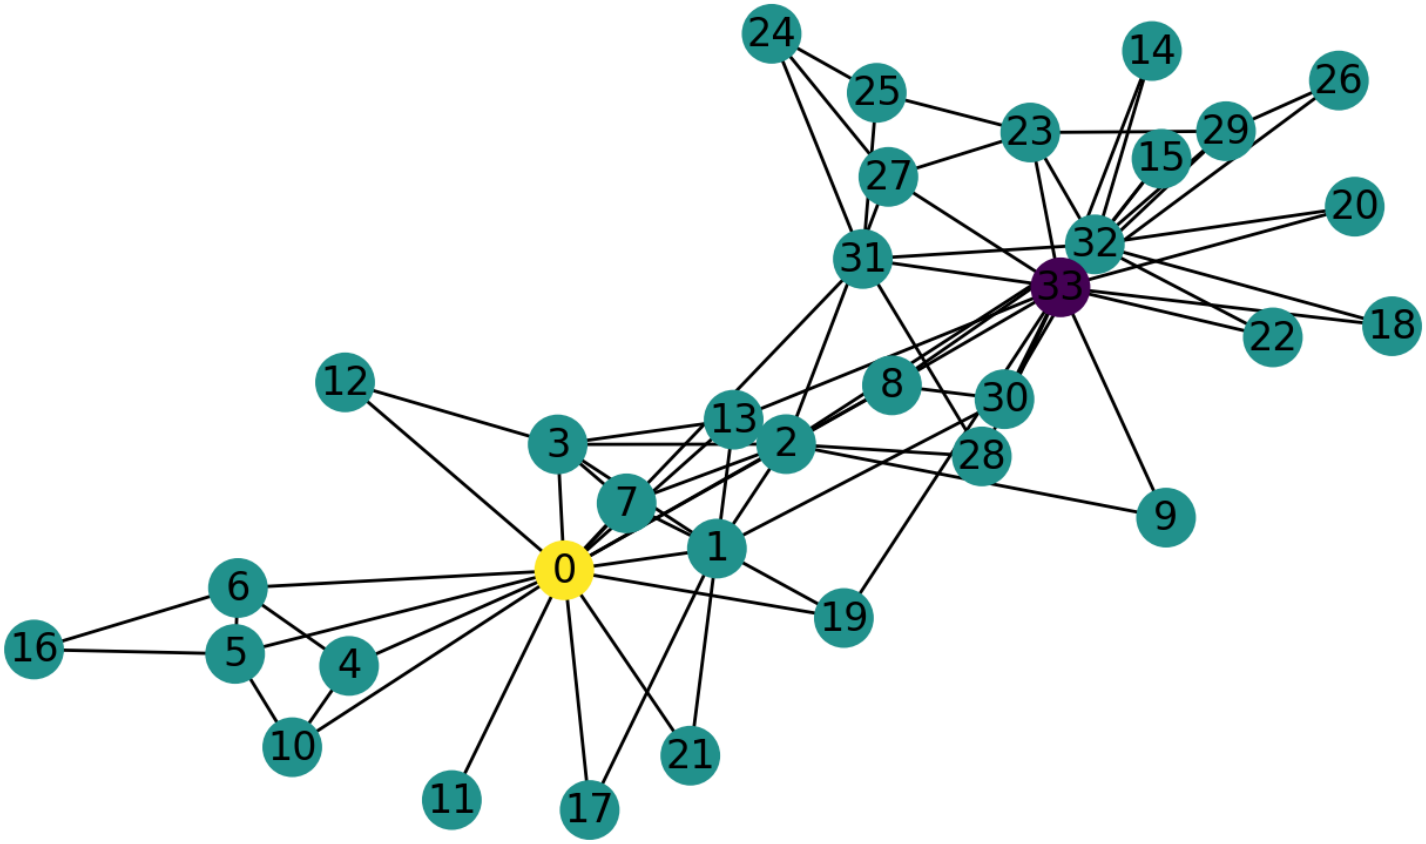


Figure 10: Difusão com $t = 0$

Efeito do operador de difusão

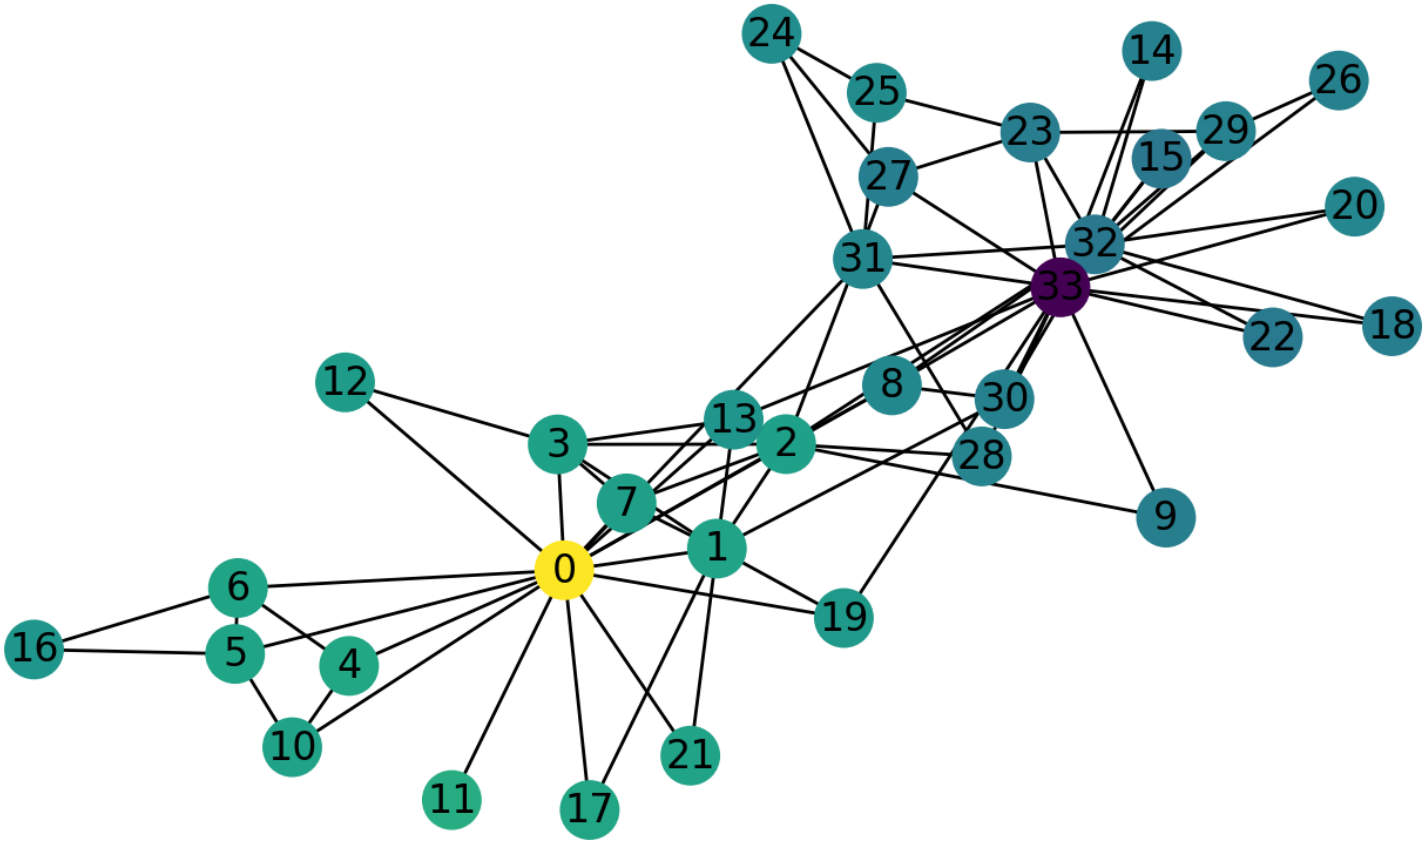


Figure 11: Difusão com $t = 1$

Efeito do operador de difusão

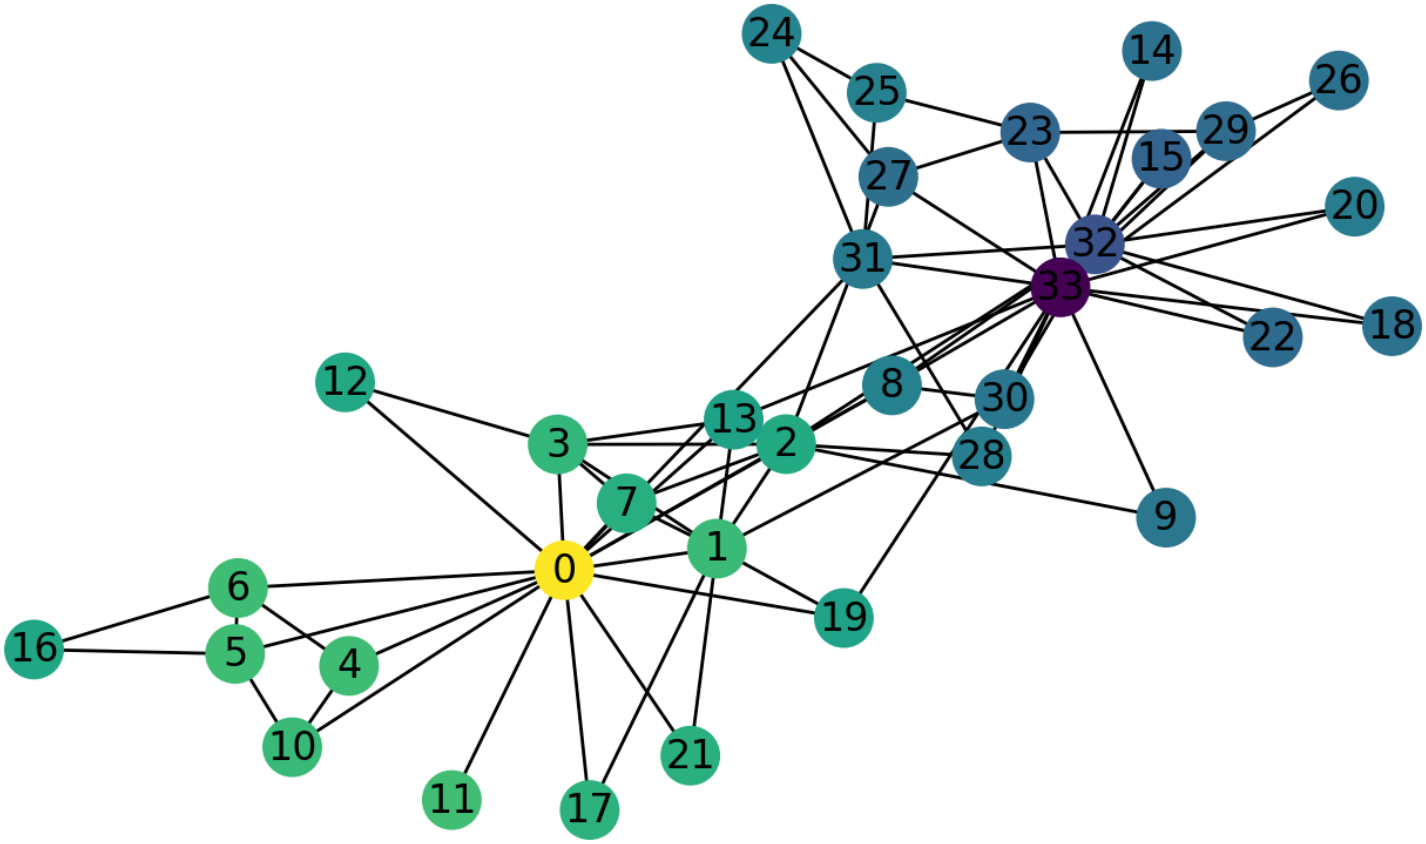


Figure 12: Difusão com $t = 2$

Efeito do operador de difusão

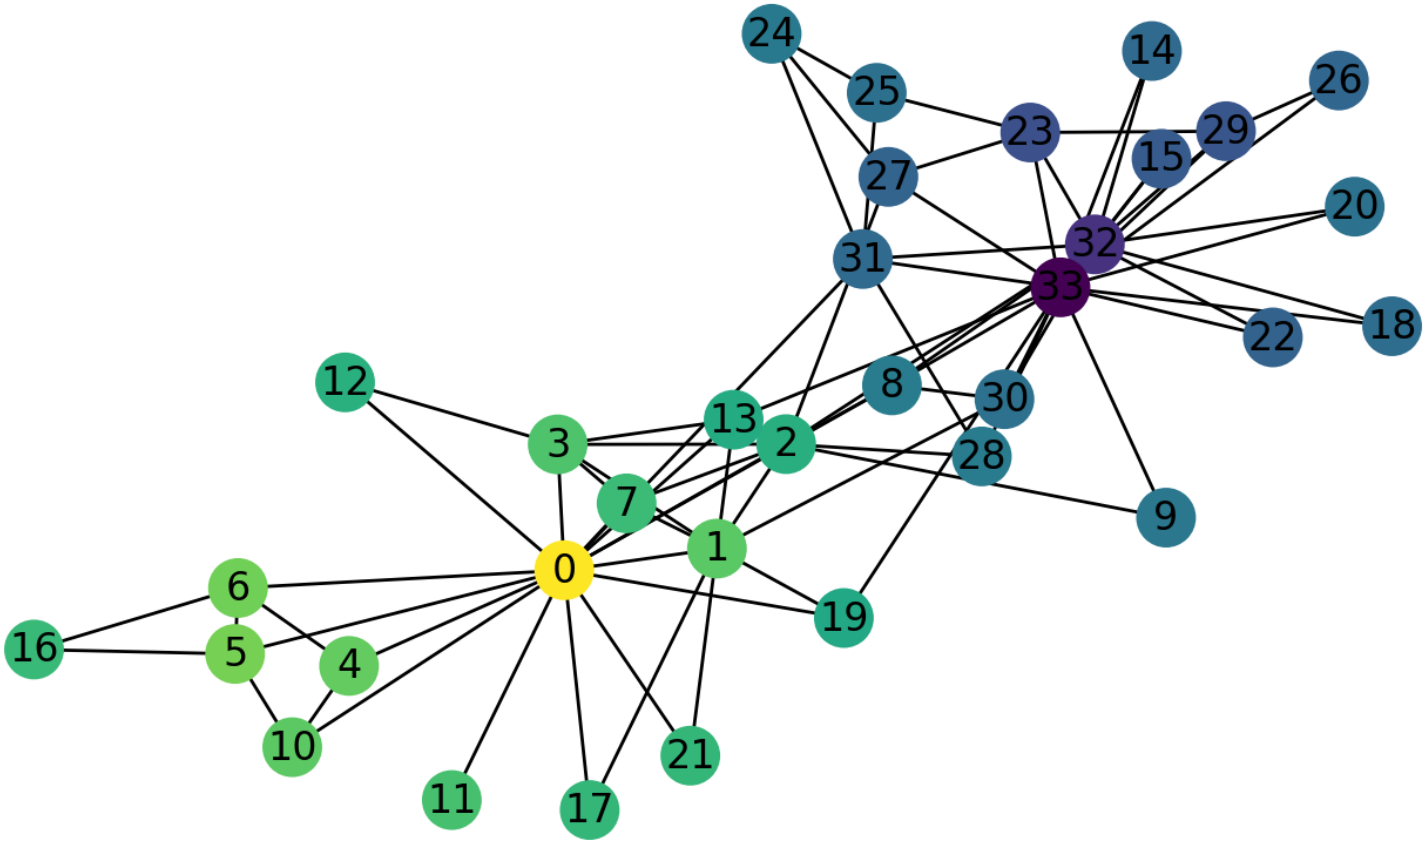


Figure 13: Difusão com $t = 3$

Efeito do operador de difusão

A difusão em grafos tem um efeito parecido com o *blur* na imagem. De fato, é a mesma operação.

Os operadores apresentados podem ser interpretados como filtros sobre os dados. Fazemos a transformação para o domínio espectral e retiramos frequências indesejadas. Normalmente, frequências mais altas representam ruídos e assim, é importante filtrá-las.

Equivalência entre os Operadores

Série Geométrica para Matrizes

$$\sum_{k=0}^{\infty} A^k = (I - A)^{-1}$$

Série de Maclaurin para Matrizes

$$e^A = \sum_{k=0}^{\infty} \frac{A^k}{k!} = I + A + \frac{A^2}{2!} + \frac{A^3}{3!} + \dots$$

Equivalência entre os Operadores

Utilizando as séries, podemos escrever

$$exp(-tL) = I - tL + \frac{t^2L^2}{2!} + \frac{t^3L^3}{3!} + \dots$$

Para $t \to 0$, podemos aproximar a série com

$$exp(-tL) \approx I - tL$$

Lembrando que a Laplaciana normalizada é $L = I - W$, temos:

$$exp(-tL) \approx I - t(I - W) = I - tI + tW$$

Equivalência entre os Operadores

Por outro lado, também podemos reescrever o operador de Autoregressão Espacial utilizando a série geométrica

$$(I - \rho W)^{-1} = I + \rho W + (\rho W)^2 + \ldots$$

Para valores pequenos de ρ, aproximamos como

$$(I - \rho W)^{-1} \approx I + \rho W$$

Vemos que a menos de um termo tI, para $\rho = t \to 0$, a regressão autoespacial é uma aproximação linear da difusão

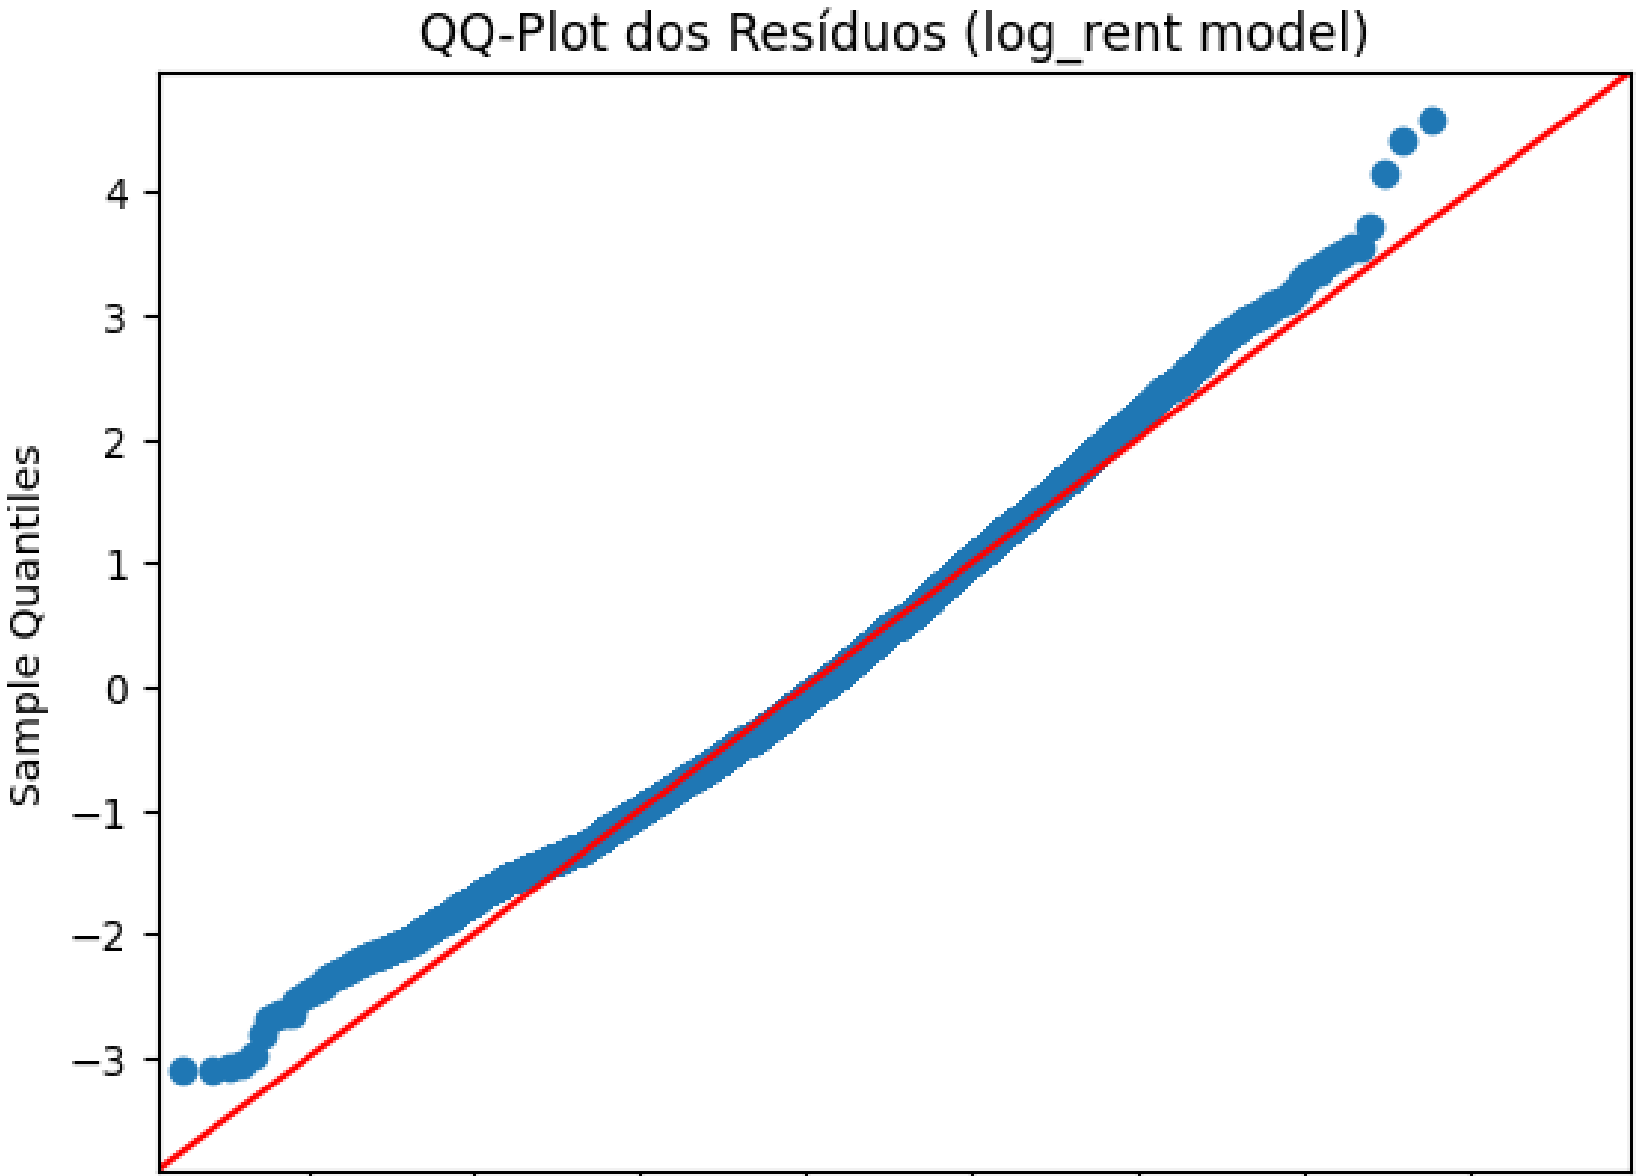
$$exp(-tL) \approx (I - \rho W)^{-1}$$

Sumário da Regressão para Modelo Linear

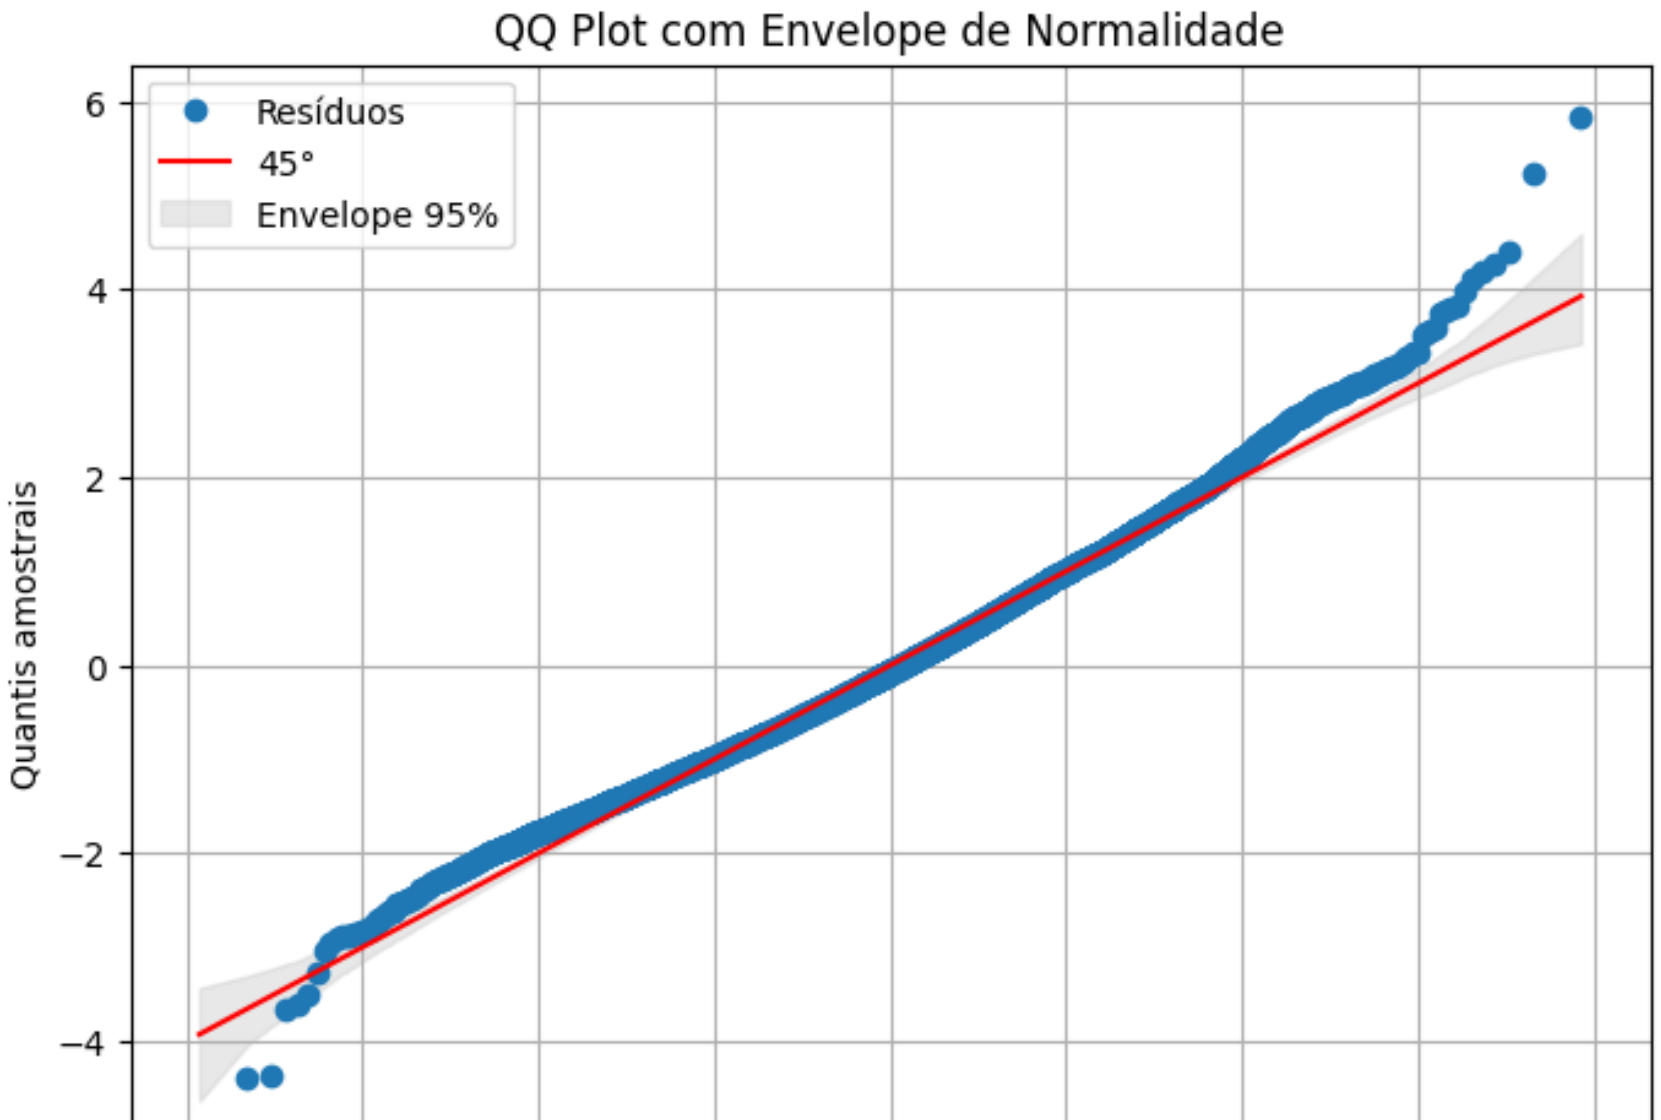
Statistic	Value
Dep. Variable	log rent
Model	OLS
No. Observations	11657
R-squared	0.563
Prob (F-statistic)	0.00

Term	coef	std err	t	$P > \|t\|$
const	7.2700	0.006	1124.248	0.000
area	0.0057	0.000	54.590	0.000
garage	0.2150	0.006	36.296	0.000
Casa	-0.3856	0.010	-39.078	0.000
Casa em condomínio	-0.2718	0.027	-10.202	0.000

Sumário da Regressão para Modelo Linear



Sumário da Regressão para Modelo Linear



Teste I de Moran na Laplaciana Normalizada W

$$I(W) = 0.2$$

Modelo Autoregressivo

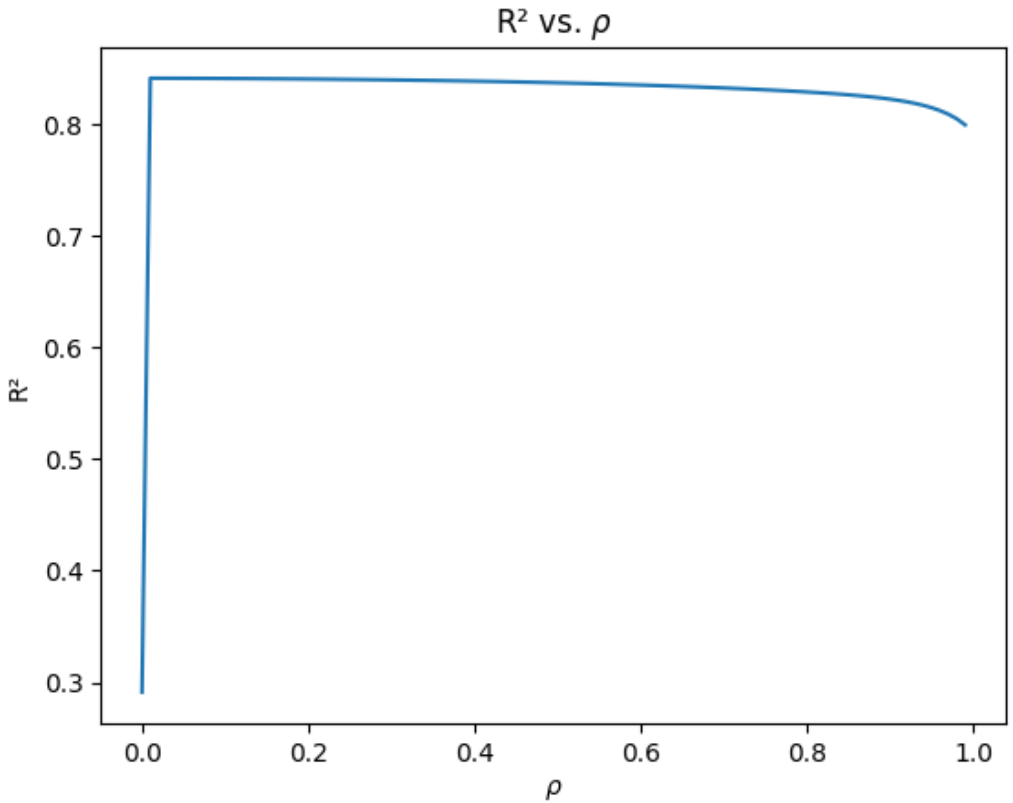


Figure 16: Coeficiente de determinação para diversos valores de ρ

Modelo de Difusão

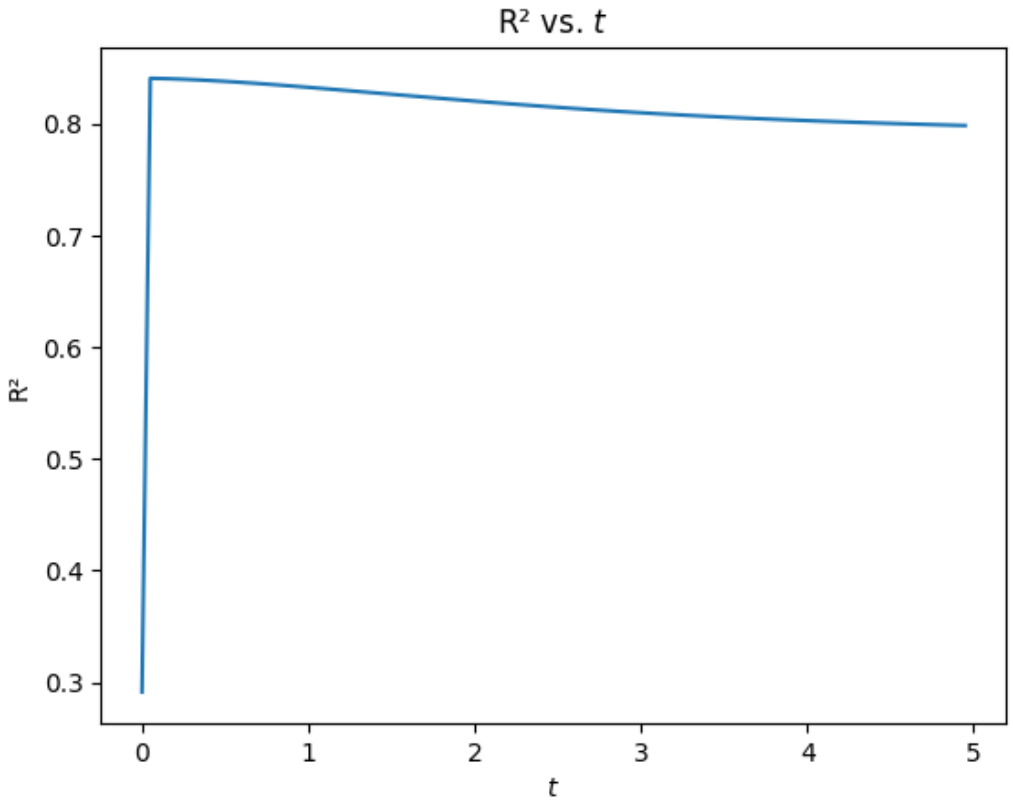


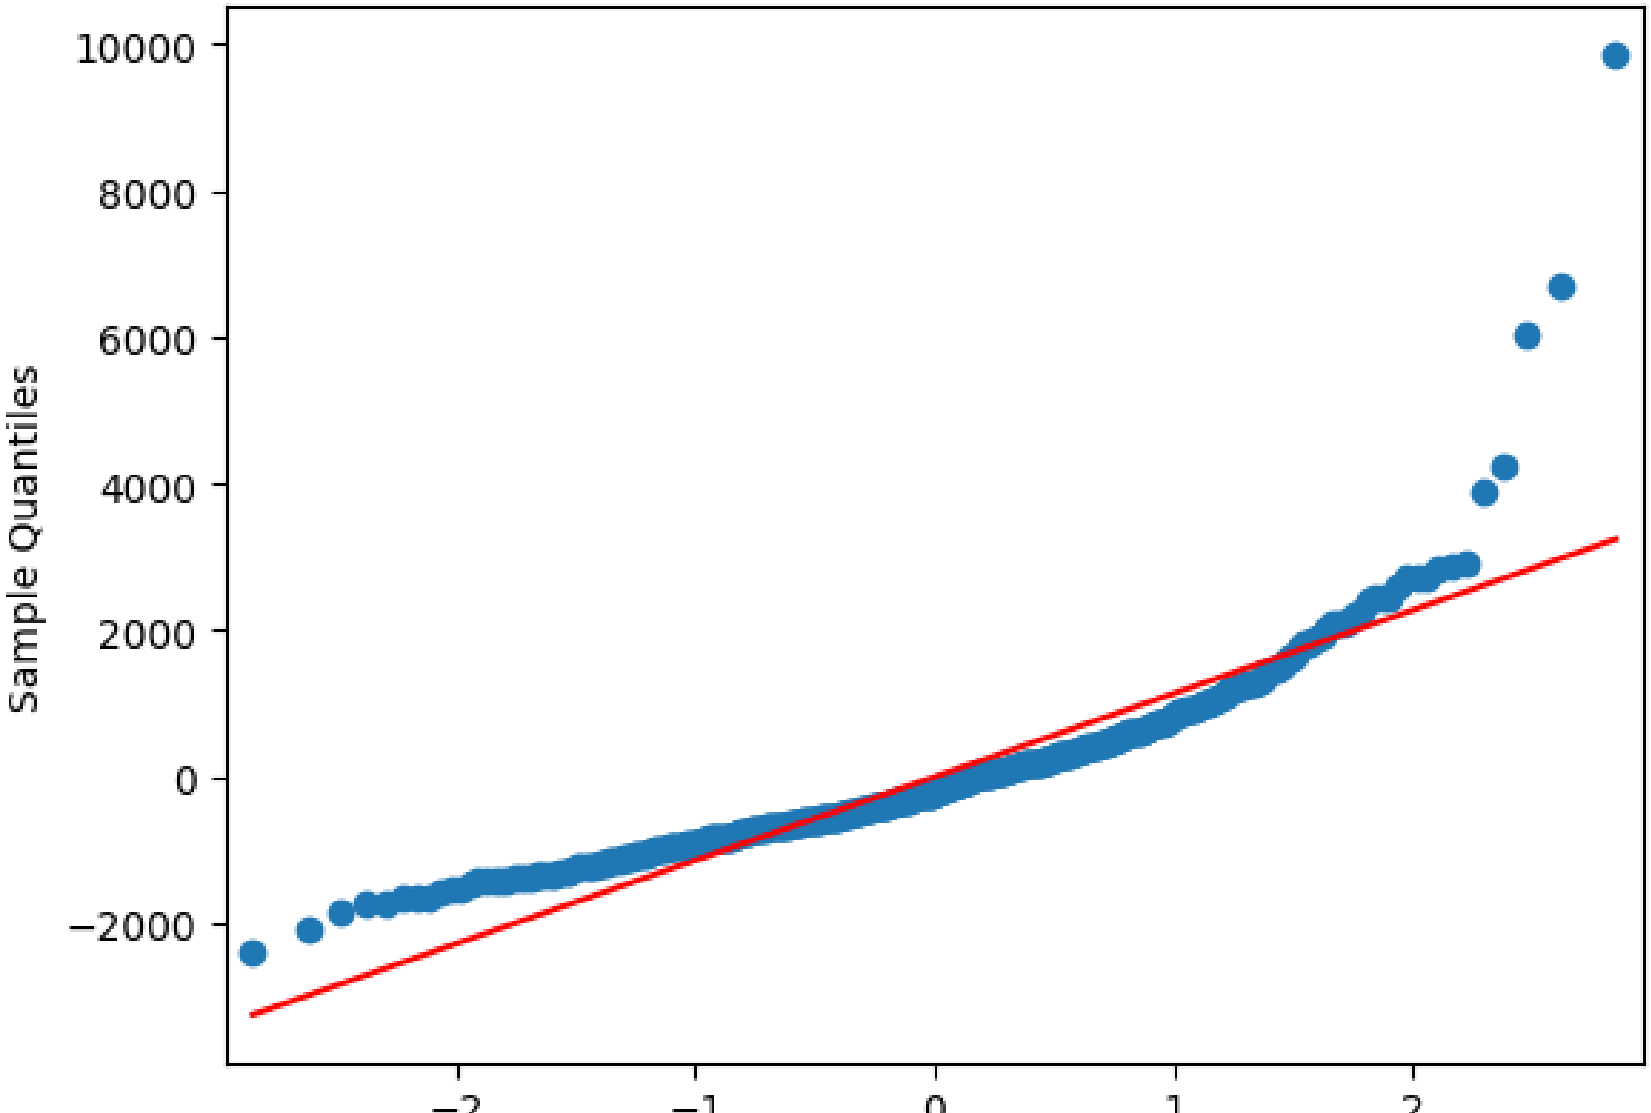
Figure 17: Coeficiente de determinação para diversos valores de t

Sumário da Regressão para Modelo Espacial

Statistic	Value
Dep. Variable	rent
Model	OLS
No. Observations	459
R-squared (uncentered)	0.831
Prob (F-statistic)	4.48e-171

Term	coef	std err	t	P>
const	733.2552	127.659	5.744	0.000
area	25.6109	2.484	10.311	0.000
garage	438.7155	95.088	4.614	0.000
Casa	-960.9371	157.674	-6.094	0.000
Casa em condomínio	-510.6751	404.941	-1.261	0.208
Studio e kitnet	461.9478	145.287	3.180	0.002

Sumário da Regressão para Modelo Espacial



Sumário da Regressão para Modelo Espacial

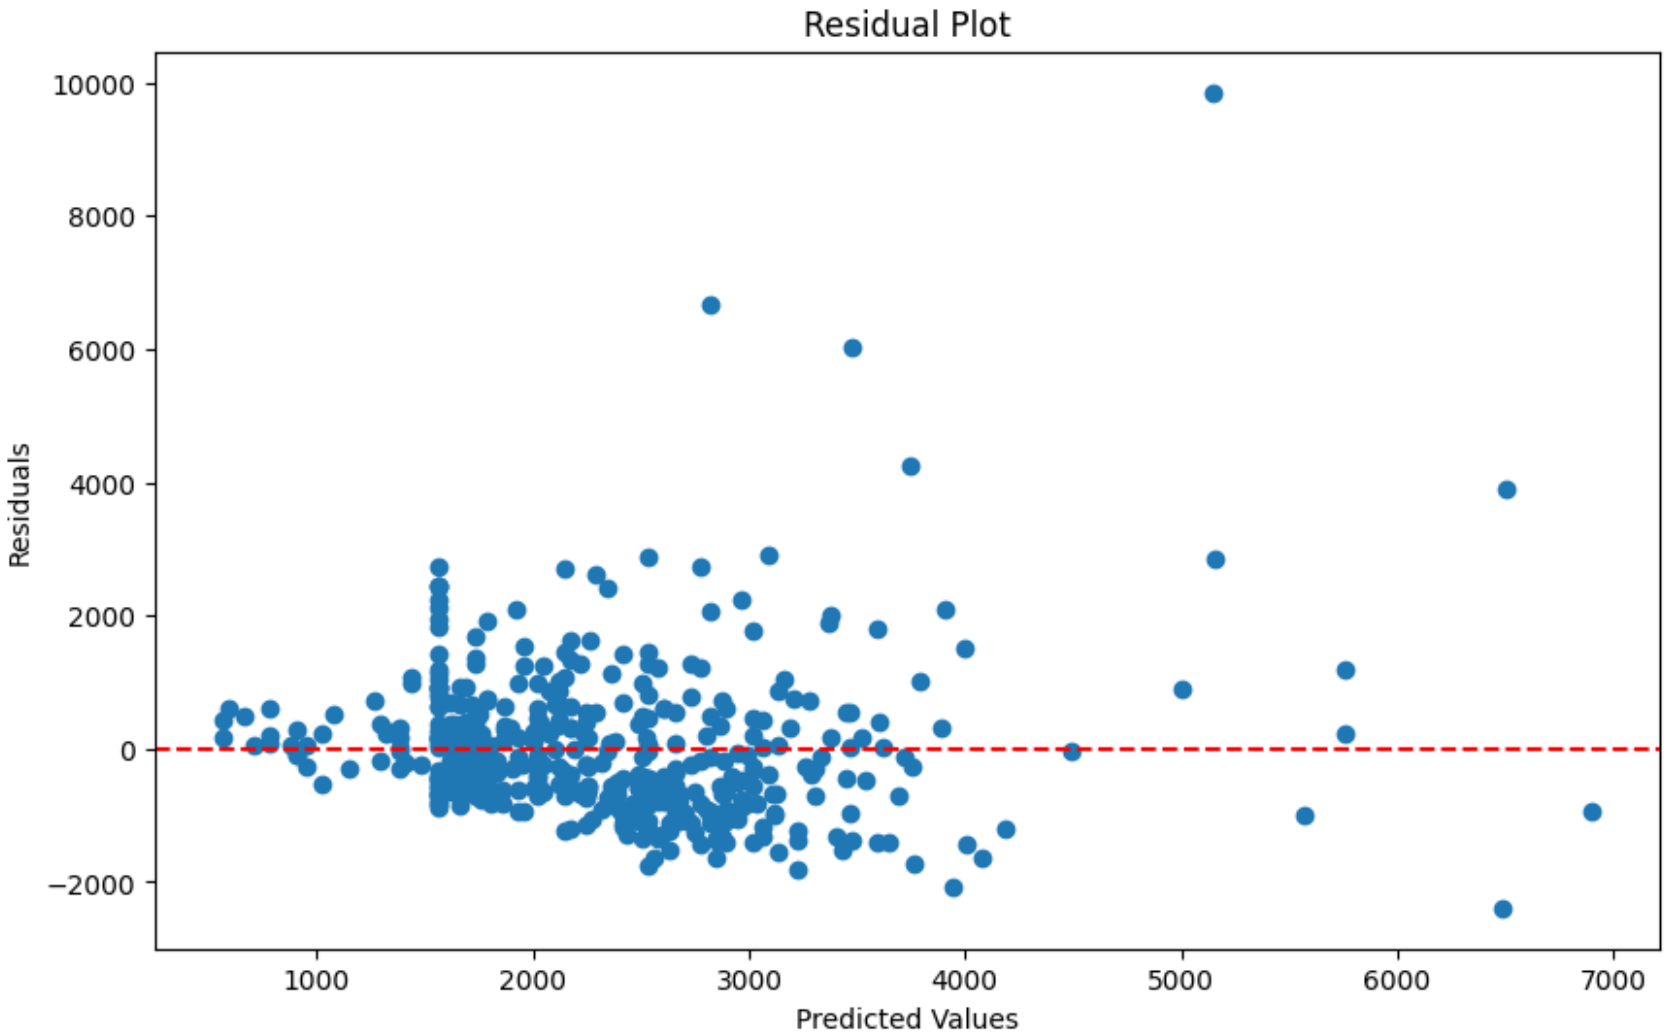


Figure 19: Resíduos do Modelo Espacial