

Lista 3 - Decomposição SVD

1. Troca de linhas e colunas.

Considere uma matriz $A_{m \times n}$ cuja decomposição SVD é dada por:

$$A = U\Sigma V^T$$

- a) O que acontece com as componentes U , Σ e V se trocarmos de posição duas colunas de A (por exemplo, as duas primeiras colunas de A)?
- b) O que acontece com as componentes U , Σ e V se trocarmos de posição duas linhas de A (por exemplo, as duas primeiras linhas de A)?

2. Posto de A .

Considere uma matriz $A_{m \times n}$ cuja decomposição SVD é dada por:

$$A = U\Sigma V^T$$

- a) Mostre que a quantidade de valores singulares não-nulos em Σ é igual ao posto de A .
- b) Mostre que, se uma matriz A tem posto r , então $A^T A$ e AA^T também têm posto r .

3. Decomposição SVD da matriz transposta.

Se uma decomposição em valores singulares da matriz $A_{m \times n}$ é

$$A = U\Sigma V^T,$$

encontre uma SVD para A^T . Como estão relacionados os valores singulares de A e A^T ?

4. Decomposição em projeções.

Considere uma matriz $A_{m \times n}$ de posto r cujos valores singulares não nulos são $\sigma_1, \dots, \sigma_r$, os vetores singulares à esquerda são u_1, \dots, u_m e os vetores singulares à direita são v_1, \dots, v_n . Mostre que A pode ser escrita como uma soma de projeções, ou de matrizes de posto 1:

$$A = \sigma_1 u_1 v_1^T + \dots + \sigma_r u_r v_r^T$$

5. Interpretação geométrica.

Considere uma matriz $A_{3 \times 2}$ e uma transformação linear $T: \mathbb{R}^2 \rightarrow \mathbb{R}^3$, em que:

$$T(\mathbf{x}) = A\mathbf{x}$$

Considere também a circunferência de raio 1, representada por:

$$\{\mathbf{x} \in \mathbb{R}^2 \mid \|\mathbf{x}\|_2 = 1\}$$

- a) Sabendo que a matriz A possui decomposição SVD na forma $A = U\Sigma V^T$, descreva a interpretação geométrica de cada operação da aplicação de T em \mathbf{x} :

$$T(\mathbf{x}) = U\Sigma V^T \mathbf{x}$$

- b) [Matlab] Faça um plot das formas geométricas resultantes da aplicação de T na circunferência de raio 1 para a seguinte matriz A :

$$A = \begin{bmatrix} 1 & -1 \\ -1.4 & 1.4 \\ 2 & -1 \end{bmatrix}$$

e compare com a interpretação geométrica realizada no item anterior.

6. Decomposição SVD de matrizes quadradas.

Considere uma matriz quadrada $A_{n \times n}$. Sabemos que nem toda matriz A possui uma diagonalização do tipo $A = PDP^T$ (com P ortonormal e D diagonal). No entanto, note que toda matriz A admite uma decomposição SVD do tipo $A = U\Sigma V^T$ (com U e V ortonormais, e Σ diagonal).

- a) Suponha A invertível com decomposição SVD na forma $A = U\Sigma V^T$. Encontre uma SVD para A^{-1} .
- b) Mostre que, se A é positiva definida e simétrica, então a decomposição SVD pode ser simplificada da forma $A = PDP^T$. Ou seja:
- os valores singulares de A coincidem com os autovalores de A ;
 - os vetores singulares de A coincidem com os autovetores de A ;

e podemos fazer $D = \Sigma$ e $P = U = V$, obtendo $A = PDP^T$.

7. Não-unicidade da decomposição SVD.

Mostre, através de um exemplo, que a decomposição SVD de uma matriz pode não ser única.

8. Aproximação com redução de posto.

Seja A uma matriz $m \times n$ de posto r , com valores singulares não nulos $\sigma_1 > \sigma_2 > \dots > \sigma_r > 0$. Sejam u_1, \dots, u_r os vetores singulares à esquerda de A , e v_1, \dots, v_r os vetores singulares à direita de A . A matriz A pode ser representada por uma soma de matrizes de posto 1:

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T$$

Considere o conjunto de todas as matrizes $B_{m \times n}$ que podem ser formadas por somas parciais da somatória acima. Por exemplo, podemos escolher apenas 1 termo qualquer da somatória de A :

$$B = \sigma_i u_i v_i^T \quad \forall i \in \{1, \dots, r\}$$

ou podemos escolher 2 termos quaisquer da somatória de A :

$$B = \sigma_i u_i v_i^T + \sigma_j u_j v_j^T \quad \forall i, j \in \{1, \dots, r\}, i \neq j$$

ou podemos escolher qualquer outra combinação de termos, até totalizar r termos.

Dentre todas as combinações possíveis, deseja-se encontrar a matriz B de posto k , onde $k < r$, que seja a melhor aproximação possível de A em termos da norma de Frobenius — isto é, que minimize $\|A - B\|_F$. Lembrando que a norma de Frobenius de uma matriz $M_{m \times n}$ pode ser definida como:

$$\|M\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n m_{ij}^2} = \sqrt{\text{traço}(MM^T)}$$

onde o traço é a soma dos elementos da diagonal principal.

Assim, mostre que a melhor escolha para B é dada pela soma dos primeiros k termos da decomposição SVD de A , ou seja,

$$B = \sum_{i=1}^k \sigma_i u_i v_i^T,$$

mantendo apenas os k maiores valores singulares $\sigma_1, \dots, \sigma_k$ e descartando os demais. Em outras palavras, mostre que a melhor aproximação de A de posto k (dentre as possibilidades de B), em norma de Frobenius, é obtida ao truncar a decomposição SVD de A nos k primeiros termos.