Lista 6 - Variância e *Principal Component Analysis* (PCA)

1. Considere um conjunto de dados bidimensionais com os três pontos:

$$\mathbf{p}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{p}_2 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{p}_3 = \begin{bmatrix} 3 \\ 4 \end{bmatrix}.$$

a) Encontre o centroide, ou o ponto médio,

$$\overline{\mathbf{p}} = \frac{1}{N} \sum_{j=1}^{N} \mathbf{p}_j,$$

em que N é a quantidade de pontos no conjunto.

b) Note que o centroide se encontra no centro geométrico dos dados, então a dispersão (espalhamento) dos dados poderá ser medida pela distância dos pontos em relação ao centroide. Para simplificar os cálculos, determine os pontos com a média removida (isto é, com o centroide na origem),

$$\widetilde{\mathbf{p}}_j = \mathbf{p}_j - \overline{\mathbf{p}}.$$

c) Agora que os dados estão centrados (com a média removida), vamos definir a variância total como a média dos quadrados das distâncias em relação à origem; ou seja, a variância total é

$$V = \frac{1}{N} \sum_{j=1}^{N} \|\widetilde{\mathbf{p}}_j\|_2{}^2.$$

Encontre a variância total V para o nosso conjunto de três pontos.

d) Projete os pontos $\widetilde{\mathbf{p}}_j$ sobre o eixo x e encontre a variância V_x dos pontos projetados ao longo desse eixo. Faça o mesmo com o eixo y para obter V_y.

e) Qual das variâncias, V_x ou V_y, é maior? O que você nota sobre a relação entre V, V_x e V_y? Como o teorema de Pitágoras explica essa relação?

f) Projete os pontos $\widetilde{\mathbf{p}}_j$ nas linhas definidas pelos vetores

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix},$$

e encontre as variâncias $V_{\mathbf{v}_1}$ e $V_{\mathbf{v}_2}$ dos pontos projetados ao longo desses vetores.

g) Qual é a relação entre a variância total V e $V_{\mathbf{v}_1}$ e $V_{\mathbf{v}_2}$? Como o teorema de Pitágoras explica sua resposta?

2. Se W é um subespaço vetorial com base ortonormal $\mathbf{u}_1, \mathbf{u}_2, \ldots, \mathbf{u}_n$, mostre que a variância de pontos projetados em W é a soma das variâncias nas direções de $\mathbf{u}_j$:

$$V_W = V_{\mathbf{u}_1} + V_{\mathbf{u}_2} + \cdots + V_{\mathbf{u}_n}.$$

Essa propriedade é conhecida como a aditividade da variância, porque a variância total é igual à soma das variâncias ao longo de cada vetor ortonormal da base do espaço vetorial.

3. Vamos voltar ao conjunto de dados da Questão 1, no qual calculamos os pontos centrados $\widetilde{p}_j$. Nosso objetivo é calcular a variância $V_{\mathbf{u}}$ na direção definida por um vetor unitário $\mathbf{u} = \begin{bmatrix} u_x \\ u_y \end{bmatrix}$.

Para começar, forme a matriz dos dados centrados

$$A = \begin{bmatrix} \widetilde{\mathbf{p}}_1 & \widetilde{\mathbf{p}}_2 & \widetilde{\mathbf{p}}_3 \end{bmatrix}.$$

a) Escreva o vetor $A^T\mathbf{u}$ em termos dos produtos internos $\widetilde{\mathbf{p}}_j \cdot \mathbf{u}$ e explique por que

$$V_{\mathbf{u}} = \frac{1}{3}\left\|A^T\mathbf{u}\right\|_2^{\,2}.$$

b) Considere a matriz

$$C = \frac{1}{N}AA^T,$$

chamada de *matriz de covariância*. Mostre analiticamente que $V_{\mathbf{u}}$ é dado pela forma quadrática

$$V_{\mathbf{u}} = u^T C u.$$

c) Explique por que a matriz de covariância C é uma matriz simétrica.

d) Use a matriz de covariância para encontrar a variância $V_{\mathbf{u}_1}$ quando

$$\mathbf{u}_1 = \begin{bmatrix} \frac{1}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} \end{bmatrix}.$$

e) Use a matriz de covariância para encontrar a variância $V_{\mathbf{u}_2}$ quando

$$\mathbf{u}_2 = \begin{bmatrix} \frac{-2}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} \end{bmatrix}.$$

f) Como $\mathbf{u}_1$ e $\mathbf{u}_2$ são ortogonais, verifique que a soma de $V_{\mathbf{u}_1}$ e $V_{\mathbf{u}_2}$ fornece a variância total.

4. Em Formas Quadráticas, vimos o *Teorema dos Eixos Principais*. Com base neste teorema, descreva como podemos determinar as direções de maior variância de um conjunto de pontos centrados cuja matriz é A, e o valor da variância em cada uma destas direções. Mostre também como a decomposição SVD pode ser utilizada para encontrar este resultado diretamente a partir de A. Dê o resultado em função de valores e vetores singulares de A.

5. Suponha que estamos trabalhando com um conjunto de dados contendo 100 pontos em cinco dimensões. A matriz de dados centrados A é, portanto, 5×100 e leva à matriz de covariância

$$C = \frac{1}{100} AA^T,$$

que é uma matriz 5×5.

Como C é simétrica, o Teorema Espectral nos diz que ela é ortogonalmente diagonalizável, então suponha que

$$C = QDQ^T,$$

onde

$$Q = \begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \mathbf{u}_3 & \mathbf{u}_4 & \mathbf{u}_5 \end{bmatrix}, \quad D = \begin{bmatrix} 13 & 0 & 0 & 0 & 0 \\ 0 & 10 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}.$$

a) Qual é $V_{\mathbf{u}_2}$, a variância na direção de $\mathbf{u}_2$?

b) Encontre a variância dos dados projetados sobre a linha definida por $\mathbf{u}_4$. O que isso nos diz sobre os dados?

c) Qual é a variância total dos dados?

d) Considere o subespaço bidimensional gerado por $\mathbf{u}_1$ e $\mathbf{u}_2$. Se projetarmos os dados nesse subespaço, que fração da variância total será representada pela variância dos dados projetados? Em outras palavras, qual é a porcentagem da variância total que pode ser explicada pelas componentes em $\mathbf{u}_1$ e $\mathbf{u}_2$?

e) Se, no item anterior, a projeção fosse feita no subespaço tridimensional gerado por $\mathbf{u}_1$, $\mathbf{u}_2$ e $\mathbf{u}_3$, qual seria a variância explicada? O que isso nos diz sobre os dados? Apesar dos dados estarem em $\mathbb{R}^5$, qual é a dimensão do subespaço que contém os dados?

f) Se aceitássemos uma variância explicada de até 50%, poderíamos reduzir a dimensionalidade dos dados para até quantas dimensões?

6. Considere uma matriz A de tamanho $m \times n$, formada por um conjunto de n pontos centrados em $\mathbb{R}^m$:

$$A = \begin{bmatrix} \widetilde{\mathbf{p}}_1 & \widetilde{\mathbf{p}}_2 & \dots & \widetilde{\mathbf{p}}_n \end{bmatrix}.$$

Se projetarmos este conjunto de pontos nas k componentes principais de maior variância, calcule qual será o erro de aproximação dado por

$$E = \sum_{j=1}^{n} \left\| \widetilde{\mathbf{p}}_j - \widetilde{\mathbf{p}}_j^{proj} \right\|_2^{\,2},$$

em que $\widetilde{\mathbf{p}}_j^{proj}$ é a projeção de um ponto $\widetilde{\mathbf{p}}_j$. Dê o resultado em função de valores e vetores singulares de A.