# Prova 2 de Teoria Espectral de Matrizes

Vítor Amorim Fróis

**Abstract**

Exercícios 3 e 4 da lista 4; 1 e 7 da lista 5; 4 e 6 da lista 6

Prova 2 de Teoria Espectral

Lista 4 - Ex 3) a)

Na questão 2, $A = \begin{bmatrix} \sigma_1 & 0 & 0 & 0 \\ 0 & \sigma_2 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$ e portanto $A^+ = \begin{bmatrix} 1/\sigma_1 & 0 & 0 & 0 \\ 0 & 1/\sigma_2 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}^T$

Dessa forma, $A^+A = \text{diag}(1,1,0,0)$. Nesse sentido, $A^+$ atua como uma quase inversa já que $A^+A$ é quase identidade como a matriz é diagonal, os autovalores correspondem aos elem. da diagonal. $A^+A$ produz uma base ortonormal correspondente aos valores singulares não nulos. De forma contrária, gera o espaço nulo correspondendo aos autovetores nulos. Assim, o comportamento de $A^+A$ corresponde com com o item d). da questão 2).

b) Mostre que $x = x^+ = A^+b$ minimiza $\|b - Ax\|_2^2$.

$A = U\Sigma V^T$ é a decomposição SVD de $A$. A inversa generalizada pode ser escrita como $A^+ = U^*\Sigma^+V^T$, onde $\Sigma^+$ inverte os autovalores² não nulos de $A$.

Vamos minimizar $\|b - Ax\|_2^2$. Considerando que mult. por ortogonal não altera o valor da norma, obtemos $\|U^T(b - Ax)\|_2^2$

$= \|U^T(b - Ax)\|_2^2 = \|U^Tb - U^TAx\|_2^2 \overset{A = U^*\Sigma V^T}{=} \|U^Tb - \Sigma V^Tx\|_2^2$

Vamos chamar $U^Tb$ de $b^*$ e $V^Tx$ de $x^*$. Assim, a nova expressão $\|b^* - \Sigma x^*\|_2^2$ é minimizada p/ $\begin{cases} x^* = b_i^*/\sigma_i, & \sigma_i \neq 0 \\ x^* = 0 & \sigma_i = 0 \end{cases}$

o caso $x^* = 0$ é utilizado para minimizar a norma.

essa solução corresponde a $x^* = \Sigma^+ b^*$.

voltando ao original, encontramos que $x^+ = A^+b$ é solução do sistema que minimiza $\|Ax - b\|_2^2$

c) No exercício anterior, $x^*$ foi escolhido de tal forma que $x_i^* = \begin{cases} b_i^*/\sigma_i, & \sigma_i \neq 0 \\ 0, & \text{c.c.} \end{cases}$ Assim, garantindo que a norma de $x^*$ seja minimizada.

$\|x^*\|_2 = \sum_{i=1}^{n} x_i^* = \sum_{i=1}^{r} b_i^*/\sigma_i + \sum_{i=r+1}^{n} 0$

$\|b^* - \Sigma(x^* + z)\|_2$ e $\|(x^* + z)\|_2^2 \Rightarrow$ para $z \neq 0$, a norma é o vetor $x^* + z$ deixa de ser o mais prox. $|x^+| < |x^* + z|$

d) O estimador de mínimos quadrados $\hat{\beta}$ vem das equações normais que encontram a projeção de $y$ no espaço $\text{col}(A)$.

$(X^TX)\beta = X^Ty$. Para resolver em função de $\hat{\beta}$, precisamos da inversa de $X^TX$, que é degenerada não existe nos casos em que $A_{m \times n}$ com $m \geq n$, de posto$(A) < n$.

Nesse caso, $\text{Ker}(A) \neq \{0\}$ e assim, existem infinitos $z$ tq. $\hat{\beta}^* = \hat{\beta} + z$, interpretado como uma liberdade de direção no espaço $\text{col}(A)$.

e) O custo computacional da solução por dec. QR é computado somando: custo de QR ($\Theta(mn^2)$ + resolução ($\Theta(mn)$),
$A \in \mathbb{R}^{m \times n}$ e $A = QR$.
De forma semelhante, o custo para computar a SVD(A) é $\Theta(m^2n^2)$
As duas soluções possuem custo $\Theta(mn^2)$, porém utilizar é mais robusto e permite lidar com problemas degenerados.

Lista 4 - Questão 4)

a) Mostre a pseudo inversa $A^+$ de A satisfaz as condições de Moore-Penrose. ~~SVD de A~~ SVD de A: $A = U\Sigma V^T$.

i) $AA^+A = A \Rightarrow AA^+A = \cancel{U(\Sigma\Sigma^+\Sigma)V^T}$
$= U\Sigma\underbrace{V^TV}_{I}\Sigma^+\underbrace{U^TU}_{I}\Sigma V^T = U(\underbrace{\Sigma\Sigma^+\Sigma}_{\Sigma})V^T = U\Sigma V^T = A$ ✓

ii) $A^+AA^+ = A^+ \Rightarrow A^+AA^+ = V\Sigma^+U^TU\Sigma V^TV\Sigma^+U^T = V(\Sigma^+\Sigma\Sigma^+)U^T$
$= V\Sigma^+U^T = A^+$ ✓

iii) $(AA^+)^T = AA^+ \rightarrow AA^+ = U\Sigma V^TV\Sigma^+U^T = U\underbrace{\Sigma\Sigma^+}U^T$
$\Sigma\Sigma^T$ é diagonal $\Rightarrow \Sigma\Sigma^T = (\Sigma\Sigma^T)^T$. Assim, $AA^+ = U(\Sigma\Sigma^T)^TU^T$
$= (AA^+)^T$

iv) mesma da iii)

b) Mostre que a inversa de Moore-Penrose é única.
Considere duas candidatas $M_1$ e $M_2$ para inversa de A

$M_1 = M_1AM_1 = M_1(AM_1)^T = M_1M_1^TA^T = M_1M_1^TA^TM_2^TA^T$
$= M_1M_1^TA^TAM_2 = M_1AM_1AM_2 = M_1AM_2 = M_1AM_2AM_2$
$= M_1AA^TM_2^TM_2 = A^TM_1^TA^TM_2^TM_2 = A^TM_2^TM_2 = M_2AM_2$

Utilizando as propriedades I, II, III, IV

# Prova de Teoria Espectral de Matrizes

## Lista 5 - Ex 1)

a) Prove que $f_A(x) = x^TAx = x^T\left(\frac{A^T + A}{2}\right)x$

$x^TAx = \frac{x^TAx}{2} + \frac{x^TAx}{2}$ ⇒ como $x^TAx$ é $1\times1$, $x^TAx = (x^TAx)^T = x^TA^Tx$

logo, $x^TAx = \frac{x^TAx}{2} + \frac{x^TA^Tx}{2} = x^T\left(\frac{A + A^T}{2}\right)x$

b) Mostre que $B = \frac{A^T + A}{2}$ é simétrica

$B$ simétrica $\Leftrightarrow B^T = B$

$B^T = \left(\frac{A^T + A}{2}\right)^T = \left(\frac{A + A^T}{2}\right) = \frac{A^T + A}{2}$ e portanto $B^T = B$.

## Lista 5 - Ex 7)

a) Dada matriz $B$, $B^TB$ é simétrica e positiva semidefinida. (PSD)

simétrica: $(B^TB)^T = B^TB$

PSD: uma matriz $A$ é PSD se $x^TAx \geq 0 \quad \forall x \neq 0$

$x^TB^TBx = \|Bx\|_2^2$. A norma retorna um valor $\geq 0$.

Assim, $B^TB$ é PSD.

b) A e B simétricas e PSD. Sua soma também é?

sim ① $A^T = A$ e $B^T = B$. Assim, $(A + B)^T = A^T + B^T$. Utilizando ①, $(A+B)^T = A + B$.

PSD $x^T(A + B)x \geq 0$. Podemos distribuir, obtendo $x^TAx + x^TBx$ ambos termos são $\geq 0$, portanto $x^T(A+B)x$ ~~é PSD~~ também e por fim, $(A+B)$ é PSD.

c) A é simétrica, invertível e positiva Definida (DP). Mostre $A^{-1}$ também.

simétrica $A^T = A \Rightarrow (A^{-1})^T = (A^T)^{-1} = (A)^{-1}$

invertível ∃ inversa de A é $A^{-1}$ t.q. $AA^{-1} = I$.

PD: uma matriz é PD quando todos seus autovalores são positivos. Assim, $A = PDP^T$, onde $D$ é $diag(\lambda_1, \lambda_2, \ldots, \lambda_n)$

$A^{-1} = PD^{-1}P^T$ é a decomposição espectral de $A^{-1}$

$D$ é uma matriz diagonal $(1/\lambda_1, 1/\lambda_2, \ldots, 1/\lambda_n)$ com valores positivos e assim, $A^{-1}$ é PD.

# Prova 2 de Teoria Espectral

## Lista 6 - Ex 4)

O teorema dos eixos principais diz que os eixos associados a uma forma quadrática são perpendiculares.



Para encontrar as direções de maior variância, considere a matriz de covariância $C = \frac{A^T A}{n}$. Podemos realizar a decomposição espectral para obter $C = Q \Sigma Q^T$. Assim, as direções de maior variância são dados pelos autovalores de $C$, colunas da matriz $Q$ e a variância associada pelo autovalor correspondentes na matriz $\Sigma = \text{diag}(\sigma_1, \sigma_2, \ldots, \sigma_n)$.

Podemos realizar o mesmo processo com SVD. Decompomos $A$ como $A = U \Sigma V^T$. considerando $C = \frac{A^T A}{n}$, temos.

$$C = (U \Sigma V^T)^T (U \Sigma V^T) \frac{1}{n} = V \Sigma^T U^T U \Sigma V^T \frac{1}{n} = V \Sigma^T \Sigma V^T$$

Nesse caso, $\Sigma^T \Sigma = \text{diag}(\sigma_1^2, \sigma_2^2, \ldots, \sigma_n^2)$ corresponde ao quadrado das variâncias e as colunas de $V$ as direções de maior variância.

## Lista 6 - Ex 6)

Primeiro faremos a decomposição de $A$ em $K$ componentes de maior variância: $A_K = \sum_{i=1}^{K} \sigma_i u_i v_i^T$, onde $u$ e $v$ vem de SVD de $A$: $A = U \Sigma V^T = \sum_{i=1}^{n} \sigma_i u_i v_i$

O erro de projeção é dado por $E = \sum_{i=1}^{n} \| p - p_{proj} \|_2^2$

A norma de Frobenius é definida como $\|X\|_F = \sqrt{\sum_{i=1}^{m} \|x_i\|_2^2}$. usamos para reescrever o erro como $E = \|A - A_K\|_F^2$.

Como a norma de Frobenius é equivalente a soma de seus valores singulares ao quadrado, $\|X\|_F^2 = \sum_{i=1}^{n} \sigma_i^2(A)$, obtemos

$$\left[ A - A_K = \sum_{i=K+1}^{n} \sigma_i u_i v_i^T \right] \qquad E = \|A - A_K\|_F^2 = \sum_i \sigma_i^2 (A - A_K)$$

isto é, o erro é a soma dos autovalores não utilizados na projeção ao quadrado

$$\boxed{E = \sum_{i=K+1}^{n} \sigma_i^2 (A)}$$